

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 1] ㉠ 어휘

1. **색인(索引)**: 어떤 항목을 쉽게 찾을 수 있도록 일정한 순서에 따라 배열한 목록.

동의어: 인덱스(index)

예문: 책 뒤편의 색인을 이용하면 원하는 내용을 빠르게 찾을 수 있다.

2. **부여(賦與)하다**: 사람이나 대상에게 어떤 권한, 자격, 의미 따위를 지니도록 해 주다.

동의어: 수여(授與)하다, 배정(配定)하다

반의어: 박탈(剝奪)하다

예문: 학교는 우수 학생에게 장학금 수혜 자격을 부여했다.

3. **수행(遂行)하다**: 일이나 임무 따위를 계획대로 해내다.

동의어: 실행(實行)하다, 이행(履行)하다

예문: 연구팀은 3년에 걸친 프로젝트를 성공적으로 수행했다.

4. **원소(元素)**: 집합을 구성하는 개별적인 대상 하나하나.

동의어: 요소(要素), 성분(成分)

예문: 집합 {1, 2, 3}에서 각각의 숫자는 하나의 원소이다.

5. **직관적(直觀的)**: 판단이나 추리 따위의 사유 과정을 거치지 않고 대상을 곧바로 파악하는.

반의어: 분석적(分析的)

예문: 이 프로그램은 직관적인 인터페이스를 갖추어 초보자도 쉽게 사용할 수 있다.

6. **유사성(類似性)**: 둘 이상의 대상이 서로 비슷한 성질이나 특성.

동의어: 유사도(類似度), 근사성(近似性)

반의어: 이질성(異質性)

예문: 두 언어 사이의 유사성을 분석하면 역사적 연관 관계를 추정할 수 있다.

7. **관계성(關係性)**: 둘 이상의 사물이나 현상이 서로 맺고 있는 연관의 정도나 성질.

동의어: 연관성(聯關性), 상관성(相關性)

예문: 수면 시간과 학업 성취도 사이의 관계성을 조사한 논문이 발표되었다.

8. **차원(次元)**: 공간이나 수학적 대상의 크기나 범위를 나타내는 독립적인 변수의 수.

예문: 3차원 공간에서는 가로, 세로, 높이의 세 방향으로 위치를 표현한다.

9. **실수(實數)**: 유리수와 무리수를 통틀어 이르는 수.

예문: 수직선 위의 모든 점은 하나의 실수에 대응된다.

10. **성분(成分)**: 하나의 대상을 이루고 있는 개별 요소.

동의어: 요소(要素), 구성분(構成分)

예문: 벡터의 각 성분을 더하면 새로운 벡터를 얻을 수 있다.

11. **전후 문맥(前後文脈)**: 어떤 단어나 문장의 앞뒤에 오는 말의 흐름이나 연결 관계.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

동의어: 맥락(脈絡), 문맥(文脈)

예문: 전후 문맥을 살피면 낯선 단어의 뜻을 짐작할 수 있다.

12. 예측(豫測)하다: 앞으로 일어날 일을 미리 짐작하여 헤아리다.

동의어: 전망(展望)하다, 추정(推定)하다

예문: 기상청은 이번 주말에 비가 올 것으로 예측했다.

13. 조정(調整)하다: 어떤 기준이나 목적에 맞도록 바로잡거나 알맞게 맞추다.

동의어: 조절(調節)하다

예문: 화면의 밝기를 눈이 편안한 수준으로 조정했다.

14. 임의(任意): 일정한 기준이나 규칙 없이 마음대로.

동의어: 무작위(無作為)로, 자의(恣意)적으로

예문: 실험 참가자를 임의로 두 집단으로 나누어 결과를 비교했다.

15. 유클리드 거리: 두 점 사이를 잇는 직선의 길이로, 피타고라스의 정리를 이용하여 구한 거리.

예문: 좌표 평면에서 (1, 2)와 (4, 6) 사이의 유클리드 거리는 5이다.


16. 코사인 유사도: 두 벡터가 이루는 각도를 기반으로 방향의 유사한 정도를 나타내는 값.

예문: 두 문서의 코사인 유사도가 1에 가까울수록 내용이 비슷하다고 판단한다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 2] 문장 독해 — 학생용 (빈칸 버전)

1) 컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다. 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 ㉠원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다. 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.	1) 중심어(구) _____, _____ 문장 독해 • 1 컴퓨터는 사람의 언어를 직접 이해할 수 없음. → 컴퓨터가 사람의 언어를 이해할 수 있도록 _____해 주어야 함. • 2 _____의 개념 : 표현하고 싶은 단어의 _____ 값에 1을 _____하고 나머지는 0을 부여하는 방법. -3 원-핫 인코딩 수행 절차 -(부연) : 먼저 대상이 되는 텍스트의 _____을 만들. -4 -(예시) : '오늘 날씨 정말 좋다.' → 단어 집합 {오늘, 날씨, 정말, 좋다}, 크기 = _____, 각 단어에 _____의 고유한 숫자를 부여. • 5 원-핫 인코딩의 한계 : _____이고 _____하지만, 단어들이 _____, _____으로 표현되기 때문에 단어들 간의 _____이나 _____을 표현하기 어려움. 중심 내용 _____
2) 이러한 단점을 개선하려는 시도가 ㉡임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다. 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다. 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.	2) 중심어(구) _____, _____, _____ 문장 독해 • 1 _____의 개념 : 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 _____ 차원으로 표현할 수 있는 방법. → 1과 0뿐만 아니라 모든 _____를 사용할 수 있음. 실제 임베딩은 _____ 차원을 사용. • 2 임베딩의 방법 중 대표적인 것 : _____(Word2Vec). -3 워드투벡은 _____으로 부여받은 숫자를 활용. -(부연) -4 -(예시) : 원-핫 인코딩으로 부여된 단어 집합 → 적절히 계산하여 _____의 고유한 숫자를 부여. • 3 이 과정을 _____이라고 함. 중심 내용 _____
3) 워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다. '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 $\odot [h_1, h_2]$를 만든다. 이때 $[h_1, h_2]$는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다. 그리고 $[h_1, h_2]$의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.	3) 중심어(구) _____, _____ 문장 독해 • 1 워드투벡에서 단어를 학습하는 방법 ① : _____을 고려하여 단어를 맞추는 것. -2 -(부연) : 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 _____하도록 학습. • 3 '날씨' 출력 과정 -(예시) : '오늘' [1, 0, 0, 0]과 '정말' [0, 0, 1, 0]의 각 _____을 적절히 계산 → _____를 만들. -4 $[h_1, h_2]$의 의미 : '날씨'를 _____하기 위해 _____들을 참고하여 만든 _____결과. • 5 $[h_1, h_2]$의 각 성분을 또 다른 방식으로 계산 → '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 _____할 수 있음. • 6 이러한 과정을 단어 집합의 _____들에 대해 수행 → 각각의 단어를 _____의 숫자로 표현 가능. 중심 내용 _____



〈그림〉

4)

단어를 학습하는 또 다른 과정은 [A]하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다. 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다. 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 @나올 확률이 높아지도록 학습한다.

4)

중심어(구) _____, _____

문장 독해

•1 워드투벡에서 단어를 학습하는 방법 ② : 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법. → 어떤 단어가 제시되면 _____를 출력하도록 학습.

•2 이웃한 단어의 범위 : _____로 정할 수 있음.

-3 -(예시) : '날씨'에 이웃한 단어의 범위를 1로 정하면 '오늘'과 '정말', 2로 정하면 '오늘', '정말', '좋다'.

•4 학습 과정 -(예시) : '날씨' [0, 1, 0, 0] 제시 → 각 성분을 적절히 계산 → $[h_1, h_2]$ → 또 다른 방식으로 계산 → '오늘'과 '정말'이 _____도록 학습.

중심 내용 _____

5)

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다. 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다. 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다. 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 로 직각을 이루면 0, 180° 로 반대 방향이면 -1의 값으로 나타낸다.

5)

중심어(구) _____, _____

문장 독해

•1 임베딩으로 표현된 단어들은 2차원의 _____ 위의 점으로 그려질 수 있음.

•2 _____에서 자주 등장하는 단어들은 좌표 평면 위에서 _____ 나타남. → 점들이 가까울수록 _____이나 관계가 깊은 것.

•3 _____ : 피타고라스의 정리를 이용해 두 점 사이를 잇는 _____의 길이를 구한 값.

•4 _____ : 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 _____, 90° 이면 _____, 180° 이면 _____의 값.


중심 내용 _____

글의 주제 : _____

[Part 3] ㉠ 독해 포인트(설명서) — 학생용 (빈칸 버전)

컴퓨터는 사람의 언어를 직접 이해할 수 없기 때문에, 컴퓨터가 이를 이해할 수 있도록 표현하는 방법이 필요하다. 그중 _____은 표현하고 싶은 단어의 색인 값에 1을, 나머지는 0을 부여하는 방법으로, _____이고 단순하지만 단어들이 개별적, 독립적으로 표현되어 단어들 간의 _____이나 _____을 표현하기 어렵다는 한계가 있다. 이를 개선하기 위해 _____이 등장하였는데, 임베딩은 원-핫 인코딩에 비해 상대적으로 _____차원으로 단어를 표현하며, 모든 _____를 사용할 수 있다. 임베딩의 대표적인 방법인 _____은 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 _____의 고유한 숫자를 부여하는 _____을 수행한다. 워드투벡의 학습 방법에는 _____을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 _____를 맞추는 방법이 있다. 이렇게 표현된 단어들은 _____위의 점으로 그려지며, 유사한 문장에서 자주 등장하는 단어들은 _____나타난다. 단어 간 거리는 _____와 _____로 측정할 수 있다.

워드투벡 임베딩 결과



<그래프 해설>

위 그래프는 워드투벡을 사용하여 음식 평가 단어들을 _____의 좌표 평면 위에 _____한 결과이다. 각 단어는 (x, y) 좌표로 표현되며, '훌륭하다'(4, 4), '맛있다'(3, 3), '보통'(1, 0), '평범하다'(0, 1), '별로'(-2, -2), '최악'(-3, -3) 등이 배치되어 있다.

㉠ 유클리드 거리 해석

그래프에서 두 점 사이의 _____(두 점 사이의 직선)이 짧을수록 두 단어의 의미가 _____. 예를 들어, '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 직선 거리가 _____의미적으로 유사한 반면, '맛있다'(3, 3)와 '최악'(-3, -3)은 직선 거리가 _____의미적으로 _____임을 알 수 있다.

㉡ 코사인 유사도 해석

그래프에서 원점(0, 0)에서 각 점까지의 _____이 이루는 각도로 유사도를 판단한다. '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 원점에서 같은 방향(y = x 직선 위)에 있으므로 두 선분이 이루는 각이 _____에 가까워 코사인 유사도가 _____에 가깝다. '보통'(1, 0)은 x축 위에 있어 원점에서의 선분이 '맛있다'(3, 3)까지의 선분과 _____를 이루므로 코사인 유사도는 약 _____으로, +1과 0의 _____에 해당한다. '평범하다'(0, 1)는 y축 위에 있어 '보통'(1, 0)과의 선분이 이루는 각이 _____이므로 코사인 유사도는 _____이다. 또한, '최악'(-3, -3)은 원점에서 '훌륭하다'(4, 4)와 _____에 위치하므로 두 선분이 이루는 각이 _____이고, 코사인 유사도는 _____이다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 4] ◎ 핵심 개념 — 학생용 (빈칸 버전)

포인트 1. _____

_____은 표현하고 싶은 단어의 _____ 값에 1을 부여하고 나머지에는 0을 부여하는 방법이다. 대상이 되는 텍스트로부터 _____을 만들고, 단어 집합의 크기에 따라 각 단어에 고유한 숫자를 부여한다. 이 방법은 _____이고 단순하지만, 단어들이 _____, _____으로 표현되어 단어들 간의 _____이나 _____을 표현할 수 없다는 한계가 있다.

포인트 2. _____

_____은 원-핫 인코딩에 비해 상대적으로 _____차원으로 단어를 표현할 수 있는 방법이다. 1과 0뿐만 아니라 모든 _____를 사용할 수 있으며, 실제로는 _____차원을 사용한다. 원-핫 인코딩의 단점인 단어들 간의 유사성·관계성 표현 문제를 개선하기 위해 제시되었다.

포인트 3. _____

_____ (Word2Vec)은 _____의 대표적인 방법으로, _____으로 부여받은 숫자를 활용하여 단어에 저차원의 고유한 숫자를 부여한다. 학습 방법에는 _____을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 _____를 맞추는 방법이 있다. 학습 과정에서 입력 단어의 각 성분을 계산하여 _____인 $[h_1, h_2]$ 를 만들고, 이를 다시 계산하여 목표 단어가 출력되도록 _____한다.

포인트 4. _____와 _____

임베딩으로 표현된 단어들은 _____위의 점으로 나타나며, 유사한 문장에서 자주 등장하는 단어들은 _____나타난다. _____는 피타고라스의 정리를 이용해 두 점 사이의 _____길이를 구한 값이고, _____는 두 선분이 이루는 각이 0° 이면 _____, 90° 이면 _____, 180° 이면 _____로 나타낸다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 5] ㉠ 내용 구조 — 학생용 (빈칸 버전)

포인트 1. 원-핫 인코딩과 임베딩의 비교

구분	원-핫 인코딩	임베딩
표현 방식	_____	_____
사용 값	_____	_____
차원	_____	_____
단어 간 관계	_____	_____
장점	_____	_____
단점	_____	-

포인트 2. 워드투벡의 두 가지 학습 방법

구분	방법 ①	방법 ②
핵심 원리	_____	_____
입력	_____	_____
출력	_____	_____
이웃 단어 범위	-	_____


포인트 3. 유사도 측정 방법

구분	유클리드 거리	코사인 유사도
원리	_____	_____
값의 범위/의미	_____	_____

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 6] 문장 독해 — 정답 버전 (괄호 해설 포함)

1) 컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다.(컴퓨터 언어 표현의 필요성) 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 ㉠원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다.(원-핫 인코딩의 개념) 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다.(원-핫 인코딩 수행 절차 - 예시) 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.(원-핫 인코딩의 한계)	1) 중심어(구) 원-핫 인코딩, 단어 집합 문장 독해 • 1 컴퓨터는 사람의 언어를 직접 이해할 수 없음. → 컴퓨터가 사람의 언어를 이해할 수 있도록 <u>표현</u>해 주어야 함. • 2 원-핫 인코딩의 개념 : 표현하고 싶은 단어의 <u>색인</u> 값에 1을 <u>부여</u>하고 나머지는 0을 부여하는 방법. - 3 원-핫 인코딩 수행 절차 -(부연) : 먼저 대상이 되는 텍스트의 <u>단어 집합</u>을 만들. - 4 -(예시) : '오늘 날씨 정말 좋다.' → 단어 집합 {오늘, 날씨, 정말, 좋다}, 크기 = 4, 각 단어에 <u>4차원</u>의 고유한 숫자를 부여. • 5 원-핫 인코딩의 한계 : <u>직관적</u>이고 <u>단순</u>하지만, 단어들이 <u>개별적, 독립적</u>으로 표현되기 때문에 단어들 간의 <u>유사성</u>이나 <u>관계성</u>을 표현하기 어려움. 중심 내용 원-핫 인코딩의 개념, 수행 절차, 한계
2) 이러한 단점을 개선하려는 시도가 ㉡임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다.(임베딩의 개념) 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다.(워드투벡의 특징) 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.(워드투벡의 학습 과정 - 예시)	2) 중심어(구) 임베딩, 워드투벡, 학습 문장 독해 • 1 임베딩의 개념 : 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 <u>낮은</u> 차원으로 표현할 수 있는 방법. → 1과 0뿐만 아니라 모든 <u>실수</u>를 사용할 수 있음. 실제 임베딩은 <u>수십 수백</u> 차원을 사용. • 2 임베딩의 방법 중 대표적인 것 : <u>워드투벡</u>(Word2Vec). - 3 워드투벡은 <u>원-핫 인코딩</u>으로 부여받은 숫자를 활용. - (부연) - 4 -(예시) : 원-핫 인코딩으로 부여된 단어 집합 → 적절히 계산하여 <u>2차원</u>의 고유한 숫자를 부여. • 3 이 과정을 <u>학습</u>이라고 함. 중심 내용 임베딩의 개념과 워드투벡의 학습 과정
3) 워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다.(워드투벡 학습 방법 ① : 전후 문맥 고려) '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 ㉢[h₁, h₂]를 만든다. 이때 [h₁, h₂]는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다.([h₁, h₂]의 의미 = 중간 계산 결과) 그리고 [h₁, h₂]의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.(학습 결과 : 단어를 2차원 숫자로 표현)	3) 중심어(구) 전후 문맥, 중간 계산 결과 문장 독해 • 1 워드투벡에서 단어를 학습하는 방법 ① : <u>전후 문맥</u>을 고려하여 단어를 맞추는 것. - 2 -(부연) : 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 <u>출력</u>하도록 학습. • 3 '날씨' 출력 과정 -(예시) : '오늘' [1, 0, 0, 0]과 '정말' [0, 0, 1, 0]의 각 <u>성분</u>을 적절히 계산 → <u>[h₁, h₂]</u>를 만들. - 4 [h₁, h₂]의 의미 : '날씨'를 <u>예측</u>하기 위해 <u>주변 단어</u>들을 참고하여 만든 <u>중간 계산</u> 결과. • 5 [h₁, h₂]의 각 성분을 또 다른 방식으로 계산 → '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 <u>조정</u>할 수 있음. • 6 이러한 과정을 단어 집합의 <u>모든 단어</u>들에 대해 수행 → 각각의 단어를 <u>2차원</u>의 숫자로 표현 가능. 중심 내용 전후 문맥을 고려한 워드투벡의 학습 방법과 [h₁, h₂]



<그림>

의 역할

4)

단어를 학습하는 또 다른 과정은 [A]하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다.(워드투벡 학습 방법 ② : 이웃한 단어 맞추기) 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다.(이웃한 단어의 범위 설정 -예시) 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 @나올 확률이 높아지도록 학습한다.(학습 과정 -예시)

5)

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다.(임베딩 결과의 시각화) 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다.(=점 간 거리가 가까울수록 의미적 유사성이 높음) 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다.(유클리드 거리의 개념) 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 로 직각을 이루면 0, 180° 로 반대 방향이면 -1의 값으로 나타낸다.(코사인 유사도의 개념)

4)

중심어(구) 이웃한 단어, 나올 확률

문장 독해

- 1 워드투벡에서 단어를 학습하는 방법 ② : 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법. → 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습.
- 2 이웃한 단어의 범위 : 임의로 정할 수 있음.
-3 -(예시) : '날씨'에 이웃한 단어의 범위를 1로 정하면 '오늘'과 '정말', 2로 정하면 '오늘', '정말', '좋다'.
- 4 학습 과정 -(예시) : '날씨' [0, 1, 0, 0] 제시 → 각 성분을 적절히 계산 → $[h_1, h_2]$ → 또 다른 방식으로 계산 → '오늘'과 '정말'이 나올 확률이 높아지도록 학습.

중심 내용 이웃한 단어를 맞추는 워드투벡의 또 다른 학습 방법

5)

중심어(구) 유클리드 거리, 코사인 유사도

문장 독해

- 1 임베딩으로 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있음.
- 2 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타남. → 점들이 가까울수록 유사한 의미이나 관계가 깊은 것.
- 3 유클리드 거리 : 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값.
- 4 코사인 유사도 : 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 이면 0, 180° 이면 -1의 값.


중심 내용 임베딩 결과의 시각화와 유사도 측정 방법

글의 주제 : 컴퓨터가 사람의 언어를 이해하기 위한 표현 방법 (원-핫 인코딩, 임베딩)과 단어 간 유사도 측정 방법

[Part 7] ◎ 독해 포인트(설명서) — 정답 버전

컴퓨터는 사람의 언어를 직접 이해할 수 없기 때문에, 컴퓨터가 이를 이해할 수 있도록 표현하는 방법이 필요하다. 그중 **원-핫 인코딩**은 표현하고 싶은 단어의 색인 값에 1을, 나머지는 0을 부여하는 방법으로, **직관적**이고 단순하지만 단어들이 개별적, 독립적으로 표현되어 단어들 간의 **유사성**이나 **관계성**을 표현하기 어렵다는 한계가 있다. 이를 개선하기 위해 **임베딩**이 등장하였는데, 임베딩은 원-핫 인코딩에 비해 상대적으로 **낮은** 차원으로 단어를 표현하며, 모든 **실수**를 사용할 수 있다. 임베딩의 대표적인 방법인 **워드투벡**은 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 **2차원**의 고유한 숫자를 부여하는 **학습**을 수행한다. 워드투벡의 학습 방법에는 **전후 문맥**을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 **이웃한 단어**를 맞추는 방법이 있다. 이렇게 표현된 단어들은 **좌표 평면** 위의 점으로 그려지며, 유사한 문장에서 자주 등장하는 단어들은 **가깝게** 나타난다. 단어 간 거리는 **유클리드 거리**와 **코사인 유사도**로 측정할 수 있다.

워드투벡 임베딩 결과



<그래프 해설>

위 그래프는 워드투벡을 사용하여 음식 평가 단어들을 **2차원**의 좌표 평면 위에 **임베딩**한 결과이다. 각 단어는 (x, y) 좌표로 표현되며, '훌륭하다'(4, 4), '맛있다'(3, 3), '보통'(1, 0), '평범하다'(0, 1), '별로'(-2, -2), '최악'(-3, -3) 등이 배치되어 있다.

① 유클리드 거리 해석

그래프에서 두 점 사이의 **직선**(두 점 사이의 직선)이 짧을수록 두 단어의 의미가 **유사하다**. 예를 들어, '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 직선 거리가 **짧아** 의미적으로 유사한 반면, '맛있다'(3, 3)와 '최악'(-3, -3)은 직선 거리가 **멀어** 의미적으로 **상이함**을 알 수 있다.

② 코사인 유사도 해석

그래프에서 원점(0, 0)에서 각 점까지의 **선분**이 이루는 각도로 유사도를 판단한다. '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 원점에서 같은 방향($y = x$ 직선 위)에 있으므로 두 선분이 이루는 각이 **0°**에 가까워 코사인 유사도가 **+1**에 가깝다. '보통'(1, 0)은 x축 위에 있어 원점에서의 선분이 '맛있다'(3, 3)까지의 선분과 **45°**를 이루므로 코사인 유사도는 약 **0.707**으로, +1과 0의 **중간**에 해당한다. '평범하다'(0, 1)는 y축 위에 있어 '보통'(1, 0)과의 선분이 이루는 각이 **90°**이므로 코사인 유사도는 **0**이다. 또한, '최악'(-3, -3)은 원점에서 '훌륭하다'(4, 4)와 **정반대 방향**에 위치하므로 두 선분이 이루는 각이 **180°**이고, 코사인 유사도는 **-1**이다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 8] ◎ 핵심 개념 — 정답 버전

포인트 1. 원-핫 인코딩

원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 대상이 되는 텍스트로부터 단어 집합을 만들고, 단어 집합의 크기에 따라 각 단어에 고유한 숫자를 부여한다. 이 방법은 직관적이고 단순하지만, 단어들이 개별적, 독립적으로 표현되어 단어들 간의 유사성이나 관계성을 표현할 수 없다는 한계가 있다.

포인트 2. 임베딩

임베딩은 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 단어를 표현할 수 있는 방법이다. 1과 0뿐만 아니라 모든 실수를 사용할 수 있으며, 실제로는 수십 수백 차원을 사용한다. 원-핫 인코딩의 단점인 단어들 간의 유사성·관계성 표현 문제를 개선하기 위해 제시되었다.

포인트 3. 워드투벡

워드투벡(Word2Vec)은 임베딩의 대표적인 방법으로, 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 저차원의 고유한 숫자를 부여한다. 학습 방법에는 전후 문맥을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 이웃한 단어를 맞추는 방법이 있다. 학습 과정에서 입력 단어의 각 성분을 계산하여 중간 계산 결과인 $[h_1, h_2]$ 를 만들고, 이를 다시 계산하여 목표 단어가 출력되도록 조정한다.

포인트 4. 유클리드 거리와 코사인 유사도

임베딩으로 표현된 단어들은 좌표 평면 위의 점으로 나타나며, 유사한 문장에서 자주 등장하는 단어들은 가깝게 나타난다. 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이의 직선 길이를 구한 값이고, 코사인 유사도는 두 선분이 이루는 각이 0° 이면 +1, 90° 이면 0, 180° 이면 -1로 나타낸다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 9] ㉠ 내용 구조 — 정답 버전

포인트 1. 원-핫 인코딩과 임베딩의 비교

구분	원-핫 인코딩	임베딩
표현 방식	색인 값에 <u>1</u> 을 부여, 나머지 <u>0</u>	상대적으로 <u>낮은 차원</u> 의 실수 벡터
사용 값	<u>1</u> 과 <u>0</u> 만 사용	모든 <u>실수</u> 사용 가능
차원	<u>단어 집합의 크기</u> 와 동일	상대적으로 <u>낮은 차원</u> (수십~수백)
단어 간 관계	<u>표현 불가</u> (개별적, 독립적)	<u>표현 가능</u> (유사 단어 근접 배치)
장점	<u>직관적</u> 이고 <u>단순</u>	단어 간 <u>유사성·관계성</u> 표현 가능
단점	단어 간 <u>유사성·관계성</u> 표현 어려움	-

포인트 2. 워드투벡의 두 가지 학습 방법

구분	방법 ①	방법 ②
핵심 원리	<u>전후 문맥</u> 을 고려하여 중간 단어 맞추기	하나의 단어로 <u>이웃한 단어</u> 맞추기
입력	<u>앞뒤 단어</u> (2개)	<u>하나</u> 의 단어
출력	사이에 들어갈 <u>하나</u> 의 단어	<u>이웃한 단어</u> 들
이웃 단어 범위	-	<u>임의</u> 로 설정 가능

포인트 3. 유사도 측정 방법

구분	유클리드 거리	코사인 유사도
원리	<u>피타고라스의 정리</u> 를 이용해 두 점 사이 <u>직선</u> 길이 계산	두 선분이 이루는 <u>각도</u> 기반
값의 범위/의미	값이 <u>작을수록</u> 유사	$0^\circ \rightarrow +1$, $90^\circ \rightarrow 0$, $180^\circ \rightarrow -1$

중요 어휘

1. **색인(索引)**: 어떤 항목을 쉽게 찾을 수 있도록 일정한 순서에 따라 배열한 목록.

동의어: 인덱스(index)

예문: 책 뒷편의 **색인**을 이용하면 원하는 내용을 빠르게 찾을 수 있다.

2. **부여(賦與)하다**: 사람이나 대상에게 어떤 권한, 자격, 의미 따위를 지니도록 해 주다.

동의어: 수여(授與)하다, 배정(配定)하다

반의어: 박탈(剝奪)하다

예문: 학교는 우수 학생에게 장학금 수여 자격을 **부여했다**.

3. **수행(遂行)하다**: 일이나 임무 따위를 계획대로 해내다.

동의어: 실행(實行)하다, 이행(履行)하다

예문: 연구팀은 3년에 걸친 프로젝트를 성공적으로 **수행했다**.

4. **원소(元素)**: 집합을 구성하는 개별적인 대상 하나하나.

동의어: 요소(要素), 성분(成分)

예문: 집합 {1, 2, 3}에서 각각의 숫자는 하나의 **원소**이다.

5. **직관적(直觀的)**: 판단이나 추리 따위의 사유 과정을 거치지 않고 대상을 곧바로 파악하는.

반의어: 분석적(分析的)

예문: 이 프로그램은 **직관적인** 인터페이스를 갖추어 초보자도 쉽게 사용할 수 있다.

6. **유사성(類似性)**: 둘 이상의 대상이 서로 비슷한 성질이나 특성.

동의어: 유사도(類似度), 근사성(近似性)

반의어: 이질성(異質性)

예문: 두 언어 사이의 **유사성**을 분석하면 역사적 연관 관계를 추정할 수 있다.

7. **관계성(關係性)**: 둘 이상의 사물이나 현상이 서로 맺고 있는 연관의 정도나 성질.

동의어: 연관성(聯關性), 상관성(相關性)

예문: 수면 시간과 학업 성취도 사이의 **관계성**을 조사한 논문이 발표되었다.

8. **차원(次元)**: 공간이나 수학적 대상의 크기나 범위를 나타내는 독립적인 변수의 수.

예문: 3**차원** 공간에서는 가로, 세로, 높이의 세 방향으로 위치를 표현한다.

9. **실수(實數)**: 유리수와 무리수를 통틀어 이르는 수.

예문: 수직선 위의 모든 점은 하나의 **실수**에 대응된다.

10. **성분(成分)**: 하나의 대상을 이루고 있는 개별 요소.

동의어: 요소(要素), 구성분(構成分)

예문: 벡터의 각 **성분**을 더하면 새로운 벡터를 얻을 수 있다.

11. **전후 문맥(前後文脈)**: 어떤 단어나 문장의 앞뒤에 오는 말의 흐름이나 연결 관계.

동의어: 맥락(脈絡), 문맥(文脈)

예문: **전후 문맥**을 살피면 낯선 단어의 뜻을 짐작할 수 있다.

12. **예측(豫測)하다**: 앞으로 일어날 일을 미리 짐작하여 헤아리다.

동의어: 전망(展望)하다, 추정(推定)하다

예문: 기상청은 이번 주말에 비가 올 것으로 **예측했다**.

13. **조정(調整)하다**: 어떤 기준이나 목적에 맞도록 바로잡거나 알맞게 맞추다.

동의어: 조절(調節)하다

예문: 화면의 밝기를 눈이 편안한 수준으로 **조정했다**.

14. **임의(任意)**: 일정한 기준이나 규칙 없이 마음대로.

동의어: 무작위(無作爲)로, 자의(恣意)적으로

예문: 실험 참가자를 **임의**로 두 집단으로 나누어 결과를 비교했다.

15. **유클리드 거리**: 두 점 사이를 잇는 직선의 길이로, 피타고라스의 정리를 이용하여 구한 거리.

예문: 좌표 평면에서 (1, 2)와 (4, 6) 사이의 **유클리드 거리**는 5이다.


16. **코사인 유사도**: 두 벡터가 이루는 각도를 기반으로 방향의 유사한 정도를 나타내는 값.

예문: 두 문서의 **코사인 유사도**가 1에 가까울수록 내용이 비슷하다고 판단한다.

[1~8] 다음 글을 읽고 물음에 답하시오.

컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다. 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. ㉠[단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다.] 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.

이러한 단점을 개선하려는 시도가 임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다. 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. ㉡[워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다.] 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 ㉢[학습]이라고 한다.



워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다. '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만든다. 이때 $[h_1, h_2]$ 는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 ㉣[중간 계산 결과]이다. 그리고 $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2

차원의 숫자로 표현할 수 있다.

단어를 학습하는 또 다른 과정은 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다. 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다. 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 나올 확률이 높아지도록 학습한다.

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다. 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다. 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다. 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 로 직각을 이루면 0, 180° 로 반대 방향이면 -1의 값으로 나타낸다.

1. 밑글의 서술 방식으로 가장 적절한 것은?

- ㉠ 대상의 한계를 지적한 뒤 이를 보완하는 새로운 방법을 소개하고 구체적 사례를 들어 설명하고 있다.
- ㉡ 서로 다른 이론들의 공통된 전제를 밝히고 각 이론의 차이점을 대비하여 제시하고 있다.
- ㉢ 특정 현상의 원인을 다양한 관점에서 분석한 뒤 하나의 결론으로 수렴시키고 있다.
- ㉣ 시간적 순서에 따라 기술의 발전 과정을 서술하고 각 단계의 장단점을 비교하고 있다.
- ㉤ 일반적 원리를 먼저 제시한 뒤 그 원리가 적용되지 않는 예외적 상황을 분석하고 있다.

2. 밑글을 이해한 내용으로 적절하지 않은 것은?

- ㉠ 원-핫 인코딩에서 단어 집합에 포함된 단어의 수가 달라지면 각 단어에 부여되는 숫자의 차원도 달라진다.
- ㉡ 임베딩에서 단어를 표현할 때 사용하는 차원의 수는 원-핫 인코딩에서 사용하는 차원의 수보다 적다.
- ㉢ 워드투벡의 학습 방법 중 하나인 단어가 주어지면 이웃한 단어를 출력하는 방식에서 이웃한 단어의 범위는 고정되어 있다.
- ㉣ 코사인 유사도에서 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 작을수록 유사도 값은 +1에 가까워진다.
- ㉤ 유클리드 거리와 코사인 유사도는 모두 좌표 평면 위에서 단어들 간의 관계를 숫자로 나타내는 방법이다.

3. ㉔에 대한 이해로 가장 적절한 것은?

- ① ㉔은 단어들 간의 관계성을 반영하여 숫자를 부여하는 방식을 설명한 것이다.
- ② ㉔에서 각 단어에 부여되는 숫자는 해당 단어가 텍스트에서 등장하는 빈도를 반영한 것이다.
- ③ ㉔에서 하나의 단어에 부여되는 숫자 중 1이 위치하는 자리는 해당 단어의 색인 값에 의해 결정된다.
- ④ ㉔에서 서로 다른 두 단어에 부여되는 숫자를 비교하면 두 단어 간의 의미적 유사성을 파악할 수 있다.
- ⑤ ㉔의 방식으로 부여된 숫자는 워드투벡에서 활용되지 않고 독립적으로만 사용된다.

4. ㉕의 이유로 가장 적절한 것은?

- ① 원-핫 인코딩이 부여하는 숫자의 차원이 임베딩이 목표로 하는 차원보다 높기 때문에, 워드투벡은 이 고차원 숫자를 저차원으로 변환하는 계산의 입력값으로 사용한다.
- ② 워드투벡은 단어 간의 유사성을 직접 측정하는 방식이 아니라, 단어의 색인 값을 재배열하는 방식이므로 원-핫 인코딩의 색인 체계를 그대로 유지해야 한다.
- ③ 임베딩 과정에서는 단어 집합 내 모든 단어를 동시에 계산해야 하므로, 각 단어를 구별할 수 있는 고유한 숫자가 이미 부여되어 있어야 계산이 가능하다.
- ④ 워드투벡의 학습 과정에서 전후 문맥 정보가 이미 원-핫 인코딩의 숫자 안에 반영되어 있으므로, 별도의 문맥 분석 절차 없이도 학습이 진행될 수 있다.
- ⑤ 원-핫 인코딩으로 부여된 숫자는 모든 실수를 사용할 수 있으므로, 워드투벡이 요구하는 연속적인 수치 계산에 곧바로 투입할 수 있다.

5. ㉖과 ㉗에 대한 이해로 적절하지 않은 것은?

- ① ㉖은 원-핫 인코딩으로 부여된 고차원의 숫자를 상대적으로 낮은 차원의 숫자로 변환하는 과정을 포함한다.
- ② ㉖의 결과로 각각의 단어는 좌표 평면 위의 점으로 표현될 수 있게 된다.
- ③ ㉗은 예측 대상 단어의 주변에 위치한 단어들의 원-핫 인코딩 값을 계산에 반영한 결과이다.
- ④ ㉗은 최종 출력값과 동일한 차원으로 구성되어 있으므로, 추가적인 차원 변환 없이 바로 출력된다.
- ⑤ ㉗의 각 성분에 대해 또 다른 방식의 계산을 수행하면 예측 대상 단어에 해당하는 원-핫 인코딩 값이 출력될 수 있다.

6. 윗글의 <그림>에 대한 이해로 적절하지 않은 것은?

- ① <그림>에서 '오늘'과 '정말'의 원-핫 인코딩 값은 각각 4개의 성분으로 이루어져 있다.
- ② <그림>에서 $[h_1, h_2]$ 는 '오늘'과 '정말'에 해당하는 원-핫 인코딩 값 각각의 성분을 계산에 반영하여 만들어진다.
- ③ <그림>에서 $[h_1, h_2]$ 의 성분 수가 2개인 것은 임베딩이 원-핫 인코딩보다 낮은 차원으로 단어를 표현하는 것과 관련된다.
- ④ <그림>에서 '날씨'에 해당하는 출력값의 성분 중 두 번째 자리에 1이 위치하는 것은 '날씨'가 단어 집합에서 두 번째 색인 값을 가지기 때문이다.
- ⑤ <그림>의 과정이 완료되면 '오늘', '정말', '날씨' 각각에 대해 $[h_1, h_2]$ 와 동일한 값이 최종적으로 부여된다.

7. 윗글을 바탕으로 <보기>를 이해한 내용으로 적절하지 않은 것은?

<보기>

같은 워드투벡의 학습 방법 중 하나의 단어가 주어지면 이웃한 단어를 출력하는 방식을 사용하여 다음과 같은 대상 텍스트를 학습시키려 한다. 단어 집합은 대상 텍스트에 등장하는 모든 단어로 구성하고, 이웃한 단어의 범위는 한 문장 내에서 1로 고정한다고 가정한다.


대상 텍스트:

고양이가 생선을 먹는다. 강아지가 생선을 먹는다. 고양이가 우유를 마신다.

이로부터 구성된 단어 집합은 {고양이가, 생선을, 먹는다, 강아지가, 우유를, 마신다}이며, 단어 집합의 크기는 6이다. 같은 이 학습을 완료한 뒤 결과를 2차원 좌표 평면에 표시하였다.

- ① '고양이가'가 제시되면 '생선을'과 '우유를'이 이웃한 단어로 출력될 확률이 높아지도록 학습될 것이다.
- ② '생선을'이 제시되면 '고양이가', '강아지가', '먹는다'가 이웃한 단어로 출력될 확률이 높아지도록 학습될 것이다.
- ③ '고양이가'와 '강아지가'는 모두 '생선을'의 이웃한 단어이므로, 좌표 평면 위에서 서로 가깝게 나타날 것이다.
- ④ '먹는다'와 '마신다'는 이웃한 단어 집합이 완전히 동일하므로, 좌표 평면 위에서 두 단어의 유클리드 거리는 0이 될 것이다.
- ⑤ '생선을'과 '우유를'은 모두 '고양이가'의 이웃한 단어이므로, 좌표 평면 위에서 양자 간의 코사인 유사도는 +1에 가까울 것이다.

8. 윗글을 바탕으로 <보기>를 이해한 내용으로 적절한 것은?




- ① P와 Q 사이의 유클리드 거리는 P와 T 사이의 유클리드 거리보다 크므로, '경제'는 '주식'보다 '금융'과 의미적 유사성이 낮다.
- ② Q와 R 사이의 유클리드 거리는 R과 S 사이의 유클리드 거리보다 크므로, '축구'는 '금융'보다 '야구'와 유사한 문장에서 자주 등장했을 것이다.
- ③ P와 R 사이의 유클리드 거리가 Q와 S 사이의 유클리드 거리보다 작으므로, '경제'와 '축구'는 '금융'과 '야구'보다 의미적으로 가까운 관계이다.
- ④ P와 S 사이의 유클리드 거리와 Q와 R 사이의 유클리드 거리가 동일하므로, '경제'와 '야구' 사이의 관계는 '금융'과 '축구' 사이의 관계와 동등한 수준이다.
- ⑤ R과 S 사이의 유클리드 거리가 P와 Q 사이의 유클리드 거리와 동일하므로, 두 쌍의 단어가 각각의 문맥에서 점유하는 의미적 위치가 대칭적이다.

[9~16] 다음 글을 읽고 물음에 답하시오.

[A] 컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다. 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다. 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.

[B] 이러한 단점을 개선하려는 시도가 임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다. 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다. 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.



워드투벡에서 단어를 학습하는 방법 중 하나는 ㉠[전후 문맥]을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다. '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만든다. 이때 $[h_1, h_2]$ 는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다. 그리

고 $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.

단어를 학습하는 또 다른 과정은 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 ㉡[이웃한 단어]를 출력하도록 학습하는 것이다. 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다. 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 나올 확률이 높아지도록 학습한다.

㉢[이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다.] 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다. 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다. 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0°이면 +1, 90°로 직각을 이루면 0, 180°로 반대 방향이면 -1의 값으로 나타낸다.

9. 밑글의 중심 화제로 가장 적절한 것은?

- ① 컴퓨터가 사람의 언어를 직접 이해하지 못하는 근본적 원인
- ② 단어를 숫자로 표현하는 방법과 단어 간 유사성을 측정하는 방식
- ③ 자연어 처리 기술의 역사적 발전 과정과 각 시기별 핵심 알고리즘
- ④ 좌표 평면 위에서 유클리드 거리와 코사인 유사도의 수학적 도출 과정
- ⑤ 원-핫 인코딩이 다른 인코딩 방식에 비해 우위를 점하게 된 기술적 배경

10. [A]와 [B]에 대한 비교로 적절하지 않은 것은?

- ① [A]에서 다루는 표현 방법은 1과 0만을 사용하지만, [B]에서 다루는 표현 방법은 모든 실수를 사용할 수 있다.
- ② [A]에서 다루는 표현 방법은 단어들을 개별적, 독립적으로 표현하지만, [B]에서 다루는 표현 방법은 단어들 간의 유사성을 반영할 수 있다.
- ③ [A]에서 다루는 표현 방법에 의해 부여된 숫자는 [B]에서 다루는 표현 방법의 계산 과정에서 입력값으로 활용된다.
- ④ [A]에서 다루는 표현 방법은 단어 집합의 크기와 동일한 차원의 숫자를 부여하지만, [B]에서 다루는 표현 방법은 그보다 낮은 차원의 숫자를 부여한다.
- ⑤ [A]에서 다루는 표현 방법은 전후 문맥을 고려하여 단어에 숫자를 부여하지만, [B]에서 다루는 표현 방법은 단어의 색인 값에 따라 숫자를 부여한다.


11. ㉠과 ㉡에 대한 이해로 가장 적절한 것은?

- ① ㉠을 고려하는 방식에서는 하나의 단어만 입력하면 되지만, ㉡을 출력하는 방식에서는 둘 이상의 단어를 입력해야 한다.
- ② ㉠을 고려하는 방식에서는 입력된 단어들 사이에 위치한 하나의 단어를 예측하지만, ㉡을 출력하는 방식에서는 입력된 단어의 앞이나 뒤에 올 단어를 예측한다.
- ③ ㉠을 고려하는 방식에서는 이웃한 단어의 범위를 임의로 정할 수 있지만, ㉡을 출력하는 방식에서는 앞뒤 각 하나의 단어로 범위가 고정되어 있다.
- ④ ㉠을 고려하는 방식과 ㉡을 출력하는 방식 모두 $[h_1, h_2]$ 를 거치지 않고 입력값에서 출력값을 바로 산출한다.
- ⑤ ㉠을 고려하는 방식은 원-핫 인코딩 값을 입력으로 사용하지만, ㉡을 출력하는 방식은 이미 임베딩이 완료된 저차원 숫자를 입력으로 사용한다.

12. ㉢를 분석한 내용으로 가장 적절한 것은?

- ① ㉢는 워드투벡의 두 가지 학습 방법이 서로 다른 결과를 산출함을 밝히기 위해, 양자의 출력값이 좌표 평면에서 상이한 위치에 나타남을 보여 주는 역할을 한다.
- ② ㉢는 임베딩의 결과로 부여된 저차원 숫자가 단어 간 유사성이라는 의미 있는 정보를 담고 있음을 보여 줌으로써, 임베딩이 원-핫 인코딩의 한계를 실질적으로 극복했음을 뒷받침하는 역할을 한다.
- ③ ㉢는 원-핫 인코딩의 고차원 숫자를 그대로 좌표 평면에 표시하면 단어 간 거리를 측정할 수 없다는 점을 지적함으로써, 유클리드 거리와 코사인 유사도의 도입 필요성을 제기하는 역할을 한다.
- ④ ㉢는 워드투벡의 학습 과정에서 $[h_1, h_2]$ 가 최종적으로 좌표 평면의 점으로 확정되는 절차를 서술함으로써, 3문단과 4문단에서 설명한 학습 과정의 구체적인 결과를 제시하는 역할을 한다.
- ⑤ ㉢는 좌표 평면에서 단어들이 무작위로 분포함을 전제한 뒤, 이로부터 유클리드 거리와 코사인 유사도라는 두 가지 측정 방법이 필요해지는 논리적 근거를 제공하는 역할을 한다.

13. 윗글을 바탕으로 <보기>를 이해한 내용으로 적절한 것은?



병은 워드투벡을 활용하여 대량의 문학 작품 텍스트를 학습시킨 뒤, 결과를 2차원 좌표 평면에 표시하였다. 그 결과는 <그림>과 같다. 병은 코사인 유사도를 이용하여 단어들 간의 관계를 분석하고자 한다. 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각도로 판단하는데, 이 각도가 0°에 가까울수록 코사인 유사도가 +1에 가까워지고, 90°에 가까울수록 0에, 180°에 가까울수록 -1에 가까워진다. 기울기가 동일하면 두 선분이 이루는 각은 0°이고, 기울기 차이가 클수록 두 선분이 이루는 각도 커진다.

- ① '왕'과 '남자' 사이의 코사인 유사도는 '여왕'과 '여자' 사이의 코사인 유사도보다 높다.
- ② '여왕'과 '남자' 사이의 코사인 유사도는 '여왕'과 '여자' 사이의 코사인 유사도보다 낮다.
- ③ '왕'과 '여왕' 사이의 코사인 유사도가 +1이므로, 두 단어는 좌표 평면에서 완전히 동일한 위치에 있다.
- ④ '남자'와 '여자' 사이의 코사인 유사도가 +1이므로, 두 단어는 유사한 문장에서 자주 등장했을 것이다.
- ⑤ '왕'과 '여자' 사이의 코사인 유사도와 '여왕'과 '남자' 사이의 코사인 유사도가 모두 +1이므로, 네 단어는 의미적으로 동등한 관계에 있다.

14. 뒷글을 바탕으로 <보기>를 이해한 내용으로 적절하지 않은 것은?

<보기>

정은 워드투백의 두 가지 학습 방법을 비교하기 위해, '철수는 사과를 좋아한다.'라는 한 문장으로 이루어진 텍스트를 대상으로 학습을 수행하려 한다. 단어 집합은 {철수는, 사과를, 좋아한다}이고, 단어 집합의 크기는 3이며, 각 단어에 원-핫 인코딩으로 [1, 0, 0], [0, 1, 0], [0, 0, 1]을 부여하였다.

방법 X: 앞뒤의 단어를 제시하면 그 사이에 들어갈 단어를 출력하도록 학습하는 방법

방법 Y: 하나의 단어가 주어지면 이웃한 단어를 출력하도록 학습하는 방법

정은 방법 X와 방법 Y를 각각 적용하여 학습을 수행한 뒤, 그 결과를 비교하고자 한다. 방법 Y에서 이웃한 단어의 범위는 1로 고정한다.

- ① 방법 X에서 '철수는'과 '좋아한다'가 입력되면 '사과를'이 출력되도록 학습될 것이다.
- ② 방법 X의 학습 과정에서 '철수는'에 해당하는 [1, 0, 0]과 '좋아한다'에 해당하는 [0, 0, 1]의 각 성분이 계산에 활용될 것이다.
- ③ 방법 Y에서 '사과를'이 입력되면 '철수는'과 '좋아한다'가 나올 확률이 높아지도록 학습될 것이다.
- ④ 방법 X에서 '사과를'에 대한 $[h_1, h_2]$ 는 '철수는'과 '좋아한다'의 원-핫 인코딩 값을 계산에 반영하여 만들어지고, 방법 Y에서 '사과를'에 대한 $[h_1, h_2]$ 는 '사과를' 자체의 원-핫 인코딩 값을 계산에 반영하여 만들어질 것이다.
- ⑤ 방법 X와 방법 Y 모두에서 $[h_1, h_2]$ 는 예측 대상 단어의 원-핫 인코딩 값과 동일한 차원으로 구성될 것이다.

15. ㉠가 참이라고 할 때, ㉡를 강화하는 것만을 <보기>에서 있는 대로 고른 것은?

<보기>

ㄱ. 대규모 뉴스 기사 텍스트를 학습시킨 결과, '대통령'과 '국회'에 해당하는 점이 좌표 평면에서 서로 가깝게 나타났다.

ㄴ. 특정 전문 분야의 논문 텍스트를 학습시킨 결과, 해당 분야에서만 함께 쓰이는 전문 용어들이 좌표 평면에서 하나의 군집을 형성하였다.

ㄷ. 여러 언어의 텍스트를 혼합하여 학습시킨 결과, 서로 다른 언어에 속하지만 번역 관계에 있는 단어들이 좌표 평면에서 가깝게 나타났다.

- ① ㄱ
- ② ㄴ
- ③ ㄱ, ㄴ
- ④ ㄱ, ㄷ
- ⑤ ㄱ, ㄴ, ㄷ


16. 뒷글을 바탕으로 할 때, 만약 원-핫 인코딩의 차원이 극도로 높아질 경우에 대한 추론으로 가장 적절한 것은?

- ① 단어 집합의 크기가 커지더라도 각 단어에 부여되는 원-핫 인코딩 값의 차원은 일정하게 유지될 것이다.
- ② 원-핫 인코딩 값의 차원이 높아지면 단어들 간의 유사성이 자동으로 반영되어 임베딩의 필요성이 줄어들 것이다.
- ③ 원-핫 인코딩 값의 차원이 높아지더라도 각 단어의 숫자에서 1이 하나만 존재하는 구조는 유지되므로, 단어들 간의 관계성을 표현하기 어려운 한계는 여전할 것이다.
- ④ 원-핫 인코딩 값의 차원이 높아지면 워드투백이 이를 활용하여 학습하는 과정에서 $[h_1, h_2]$ 의 성분 수도 반드시 함께 높아져야 할 것이다.
- ⑤ 원-핫 인코딩 값의 차원이 높아지면 코사인 유사도가 항상 0에 가까워지므로, 유클리드 거리만으로 단어 간 유사성을 측정해야 할 것이다.

[17~24] 다음 글을 읽고 물음에 답하시오.

컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다. 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 ㉠[단어 집합]을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다. 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.

이러한 단점을 개선하려는 시도가 임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다. 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다. 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.



워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다. '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만든다. 이때 $[h_1, h_2]$ 는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다. 그리고 $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. ㉡[이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.]

㉠[단어를 학습하는 또 다른 과정은 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다.] 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다. 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다. 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 나올 확률이 높아지도록 학습한다.

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다. 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다. 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다. ㉢[코사인 유사도]는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0°이면 +1, 90°로 직각을 이루면 0, 180°로 반대 방향이면 -1의 값으로 나타낸다.

17. 밑글의 각 문단에 대한 설명으로 적절하지 않은 것은?

- ㉠ 1문단은 컴퓨터가 사람의 언어를 이해하기 위한 표현의 필요성을 제시한 뒤, 원-핫 인코딩의 방법과 그 한계를 설명하고 있다.
- ㉡ 2문단은 1문단에서 지적한 한계를 보완하는 임베딩의 개념과 그 대표적 방법인 워드투벡을 소개하고 있다.
- ㉢ 3문단은 워드투벡의 학습 방법 중 하나를 구체적 사례를 통해 설명하면서, 학습 과정에서의 중간 계산 결과의 역할을 밝히고 있다.
- ㉣ 4문단은 3문단에서 설명한 학습 방법이 지닌 한계를 지적하고, 이를 극복하기 위해 새로운 알고리즘을 도입하는 과정을 서술하고 있다.
- ㉤ 5문단은 학습 결과로 표현된 단어들의 분포 특성을 설명하고, 단어 간 거리를 수치로 나타내는 두 가지 방법을 소개하고 있다.

18. 뒷글을 이해한 내용으로 적절한 것만을 <보기>에서 있는 대로 고른 것은?

<보기>

- ㄱ. 원-핫 인코딩에서 동일한 단어 집합에 속하는 서로 다른 두 단어에 부여된 숫자를 비교하면, 두 숫자 모두에서 동시에 1의 값을 가지는 성분의 자리는 존재하지 않는다.
- ㄴ. 워드투벡에서 전후 문맥을 고려하여 단어를 맞추는 학습 방법의 경우, 입력으로 제시되는 앞뒤 단어의 원-핫 인코딩 값은 학습의 결과로 변경되어 최종 출력에 반영된다.
- ㄷ. 좌표 평면 위에서 두 단어에 해당하는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 둔각이면, 두 단어의 코사인 유사도는 0보다 작은 값을 가진다.

- ① ㄱ
② ㄷ
③ ㄱ, ㄷ
④ ㄴ, ㄷ
⑤ ㄱ, ㄴ, ㄷ

19. ㉠이 지문에서 수행하는 역할에 대한 설명으로 가장 적절한 것은?

- ① ㉠은 원-핫 인코딩과 임베딩 모두에서 단어를 숫자로 변환하는 과정의 출발점으로 기능하며, 대상 텍스트에 포함된 단어들의 목록을 확정하는 기초 단위로 제시되고 있다.
- ② ㉠은 임베딩에서만 요구되는 고유한 전처리 단계로서, 원-핫 인코딩에서는 별도의 단어 목록 없이도 각 단어에 숫자를 부여할 수 있음을 대비적으로 보여 주는 역할을 한다.
- ③ ㉠은 단어들 간의 유사성과 관계성을 반영하여 구성되는 것으로, 유사한 의미를 가진 단어들이 동일한 집합 내에서 인접한 색인 값을 부여받도록 하는 배열 원리를 나타낸다.
- ④ ㉠은 워드투벡의 학습 과정에서 전후 문맥을 고려하는 방식과 이웃한 단어를 출력하는 방식 중 어떤 것을 선택할지 결정하는 기준으로 활용되고 있다.
- ⑤ ㉠은 코사인 유사도와 유클리드 거리를 산출하기 위해 좌표 평면에 단어를 배치할 때, 각 단어의 좌표를 결정하는 직접적 근거로 사용된다.

20. 뒷글을 바탕으로 ㉡에 대해 비판할 수 있는 내용으로 가장 적절한 것은?

- ① ㉡는 전후 문맥을 고려하는 학습 방법만을 전제로 서술되었으나, 하나의 단어로부터 이웃한 단어를 출력하는 학습 방법으로도 동일한 결과에 도달할 수 있다는 점이 고려되지 않았다.
- ② ㉡는 단어 집합의 모든 단어에 대해 학습을 수행하면 각 단어를 2차원의 숫자로 표현할 수 있다고 하였으나, 실제 임베딩에서는 수십 수백 차원이 사용된다는 점에서 2차원이라는 수치는 설명의 편의를 위한 단순화된 예시에 해당한다.
- ③ ㉡는 학습을 통해 모든 단어가 고유한 2차원의 숫자를 부여받게 된다고 전제하고 있으나, 서로 다른 단어가 우연히 동일한 좌표값을 부여받을 가능성을 배제하고 있다.
- ④ ㉡는 학습의 최종 결과만을 제시하고 있을 뿐, 학습 과정에서 $[h_1, h_2]$ 의 값이 어떠한 기준에 의해 조정되는지에 대한 구체적인 메커니즘을 설명하지 않고 있다.
- ⑤ ㉡는 단어 집합의 모든 단어에 대해 학습을 수행해야 한다고 하였으나, 대상 텍스트에 등장하지 않는 새로운 단어에 대해서는 이 방법이 적용될 수 없다는 한계를 언급하지 않고 있다.

21. ㉢의 전제로 가장 적절한 것은?

- ① 하나의 단어에 대해 앞이나 뒤에 이어질 단어의 범위를 설정하면, 그 범위 안의 모든 단어가 반드시 동일한 원-핫 인코딩 값을 가져야 한다.
- ② 텍스트에서 특정 단어의 앞이나 뒤에 어떤 단어들이 출현하는지에 관한 정보가 해당 단어의 의미를 파악하는 데 유의미하게 활용될 수 있어야 한다.
- ③ 앞뒤의 단어를 제시하여 그 사이에 들어갈 단어를 맞추는 방식으로는 단어 간의 의미적 관계를 충분히 포착할 수 없어야 한다.
- ④ 하나의 단어가 주어졌을 때 앞이나 뒤에 이어질 단어의 범위는 텍스트의 전체 길이에 비례하여 자동으로 결정되어야 한다.
- ⑤ 학습에 사용되는 텍스트의 모든 문장이 동일한 수의 단어로 구성되어 있어야 한다.

22. ㉠에 대한 이해로 적절하지 않은 것은?

- ① ㉠은 좌표 평면 위에서 단어들 간의 관계를 숫자로 표현하는 방법 중 하나이다.
- ② ㉠의 값이 +1에 가까울수록 두 단어는 유사한 의미나 관계가 깊은 것으로 이해할 수 있다.
- ③ ㉠은 두 점 사이의 직선 거리를 측정하는 것이 아니라, 원점을 기준으로 한 방향의 유사성을 측정한다.
- ④ ㉠의 값이 -1이면 두 단어에 해당하는 점이 원점을 사이에 두고 서로 반대 방향에 위치해 있음을 나타낸다.
- ⑤ ㉠의 값이 0이면 두 단어에 해당하는 점이 좌표 평면의 원점에 서로 동일한 거리에 위치해 있음을 나타낸다.

23. 윗글과 <그림>을 바탕으로 <보기>를 이해한 내용으로 적절하지 않은 것은?

<보기>


무는 '오늘 날씨 정말 좋다.'라는 텍스트에 대해 전후 문맥을 고려하여 단어를 맞추는 학습 방법을 적용하되, 예측 대상 단어의 앞뒤로 각 1개의 단어를 입력으로 사용하기로 하였다. 단어 집합은 {오늘, 날씨, 정말, 좋다}이고, 원-핫 인코딩은 각각 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]이다. 무는 이 학습을 '날씨'뿐 아니라 다른 단어에 대해서도 수행하려 한다. 단, 문장의 맨 앞이나 맨 뒤에 위치하여 앞뒤 단어가 모두 확보되지 않는 경우에는 해당 위치의 학습을 수행하지 않는다고 가정한다.

- ① '날씨'를 예측할 때에는 '오늘'의 [1, 0, 0, 0]과 '정말'의 [0, 0, 1, 0]이 입력으로 사용될 것이다.
- ② '정말'을 예측할 때에는 '날씨'의 [0, 1, 0, 0]과 '좋다'의 [0, 0, 0, 1]이 입력으로 사용될 것이다.
- ③ '오늘'은 문장의 맨 앞에 위치하여 앞 단어가 확보되지 않으므로, 이 학습에서 '오늘'을 예측 대상으로 하는 학습은 수행되지 않을 것이다.
- ④ 이 학습이 완료되면 '날씨'와 '정말'은 각각 서로 다른 2차원의 고유한 숫자로 표현될 것이다.
- ⑤ 이 학습에서 '날씨'를 예측할 때 만들어지는 $[h_1, h_2]$ 와 '정말'을 예측할 때 만들어지는 $[h_1, h_2]$ 는, 입력되는 단어가 다르므로 동일한 값이 될 수 없다.

24. 윗글을 바탕으로 <보기>를 이해한 내용으로 가장 적절한 것은?

<보기>

워드투벡 임베딩 결과 (보기 24)



기는 워드투벡을 활용하여 대규모 온라인 리뷰 텍스트에 등장하는 단어들을 2차원 좌표 평면 위의 점으로 표현하는 임베딩을 수행하였다. 그 결과는 <그림>과 같다. 기는 유클리드 거리와 코사인 유사도를 모두 활용하여 단어 간 관계를 분석하고자 한다. 유클리드 거리는 $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$ 로 구하며, 코사인 유사도는 원점에서 각 점까지의 선분이 이루는 각이 0°이면 +1, 90°이면 0, 180°이면 -1이다.

- ① '맛있다'와 '훌륭하다' 사이의 코사인 유사도는 +1이고 유클리드 거리도 0이므로, 두 단어는 좌표 평면에서 완전히 동일한 점에 위치한다.
- ② '맛있다'와 '별로' 사이의 코사인 유사도는 +1이므로, 두 단어는 유사한 문장에서 자주 등장했을 것이다.
- ③ '맛있다'와 '최악' 사이의 유클리드 거리는 '맛있다'와 '별로' 사이의 유클리드 거리보다 크고, '맛있다'와 '최악' 사이의 코사인 유사도는 '맛있다'와 '별로' 사이의 코사인 유사도와 동일하다.
- ④ '보통'과 '평범하다' 사이의 코사인 유사도는 0이므로, 두 단어가 유사한 문장에서 자주 등장했더라도 좌표 평면에서의 방향은 서로 직교하는 것으로 나타난다.
- ⑤ '별로'와 '최악' 사이의 유클리드 거리가 '맛있다'와 '훌륭하다' 사이의 유클리드 거리와 동일하므로, 부정적 의미를 지닌 단어 쌍의 유클리드 거리는 항상 긍정적 의미를 지닌 단어 쌍의 유클리드 거리와 같다.

정답 및 해설

1. 정답: ①

정답 해설: 윗글은 1문단에서 원-핫 인코딩을 설명한 뒤 단어 간 유사성이나 관계성을 표현하기 어렵다는 한계를 지적하고, 2문단 이후에서 이를 개선하기 위한 임베딩과 워드투벡을 소개하면서 구체적 사례를 들어 설명하고 있다.

오답 해설:

- ② 윗글은 원-핫 인코딩과 임베딩의 공통 전제를 밝히는 것이 아니라, 전자의 한계를 후자가 보완하는 관계로 서술하고 있다.
- ③ 특정 현상의 원인을 다양한 관점에서 분석하는 구조가 아니라, 하나의 기술적 문제에 대한 해결 방법을 순차적으로 제시하는 구조이다.
- ④ 시간적 순서에 따른 발전 과정이 아니라, 원-핫 인코딩의 한계와 임베딩의 보완이라는 논리적 흐름으로 서술하고 있다.
- ⑤ 원리의 예외적 상황을 분석하는 내용은 윗글에 나타나지 않는다.

2. 정답: ③

정답 해설: 4문단에서 "앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데"라고 하였으므로, 이웃한 단어의 범위가 고정되어 있다는 ③의 서술은 적절하지 않다.

오답 해설:

- ① 1문단에서 단어 집합의 크기에 따라 각 단어에 부여되는 숫자의 차원이 결정된다고 하였으므로 적절하다.
- ② 2문단에서 임베딩은 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있다고 하였으므로 적절하다.
- ④ 5문단에서 코사인 유사도는 두 선분이 이루는 각이 0°이면 +1이라고 하였으므로, 각이 작을수록 +1에 가까워진다는 서술은 적절하다.
- ⑤ 5문단에서 유클리드 거리와 코사인 유사도 모두 점들 간의 거리를 숫자로 나타내는 방법으로 제시되었으므로 적절하다.

3. 정답: ③

정답 해설: ③은 원-핫 인코딩의 방식을 설명한 것으로, 1문단에서 "표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법"이라고 하였다. 따라서 각 단어에 부여되는 숫자에서 1이 위치하는 자리는 해당 단어의 색인 값에 의해 결정된다.

오답 해설:

- ① ③은 원-핫 인코딩에 관한 서술인데, 1문단에서 원-핫 인코딩은 단어들 간의 유사성이나 관계성을 표현하기 어렵다고 하였으므로 적절하지 않다.
- ② ③에서 1의 위치는 단어의 색인 값에 의해 결정되는 것이지만, 텍스트에서의 등장 빈도와는 무관하다.
- ④ 1문단에서 원-핫 인코딩은 단어들이 개별적, 독립적으로 표현되어 유사성을 파악하기 어렵다고 하였으므로 적절하지 않다.
- ⑤ 2문단에서 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다고 하였으므로 적절하지 않다.

4. 정답: ①

정답 해설: ①은 "워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다."라는 문장이다. 2문단에서 임베딩은 원-핫 인코딩에 비해 낮은 차원으로 표현하는 방법이라 하였고, 워드투벡은 원-핫 인코딩으로 부여된 고차원의 숫자를 적절히 계산하여 저차원의 숫자로 변환한다고 하였다. 따라서 워드투벡이 원-핫 인코딩의 숫자를 활용하는 이유는, 원-핫 인코딩이 부여하는 고차원 숫자가 저차원으로 변환하는 계산의 입력값으로 쓰이기 때문이다.

오답 해설:

- ② 워드투벡은 색인 값을 재배열하는 것이 아니라 원-핫 인코딩 값을 계산하여 새로운 저차원 숫자를 부여하는 것이므로 적절하지 않다.
- ③ 3문단과 4문단에 제시된 학습 과정에서 단어 집합 내 모든 단어를 동시에 계산한다는 내용은 지문에 서술되어 있지 않다.
- ④ 원-핫 인코딩의 숫자에는 전후 문맥 정보가 반영되어 있지 않다. 1문단에서 원-핫 인코딩은 단어들이 개별적, 독립적으로 표현된다고 하였다.
- ⑤ 원-핫 인코딩은 1과 0만을 사용하는 방법이지, 모든 실수를 사용할 수 있는 것은 임베딩이다.

5. 정답: ④

정답 해설: 3문단에서 $[h_1, h_2]$ 는 2개의 성분으로 이루어져 있으나, 최종 출력값인 '날씨'에 해당하는 $[0, 1, 0, 0]$ 은 4개의 성분으로 이루어져 있다. 따라서 ④은 최종 출력값과 동일한 차원으로 구성되어 있지 않으며, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 4차원의 출력값을 산출하는 추가적인 과정이 필요하다.

오답 해설:

- ① 2문단에서 원-핫 인코딩으로 부여된 숫자를 적절히 계산하여 낮은 차원의 숫자를 부여하는 것이 학습이라 하였으므로 적절하다.
- ② 2문단에서 학습의 결과로 각 단어에 2차원의 고유한 숫자가 부여된다고 하였고, 5문단에서 이렇게 표현된 단어들은 좌표 평면 위의 점으로 그려질 수 있다고 하였으므로 적절하다.
- ③ 3문단에서 $[h_1, h_2]$ 는 '오늘'과 '정말'이라는 주변 단어들의 원-핫 인코딩 값을 적절히 계산하여 만든 것이라 하였으므로 적절하다.
- ⑤ 3문단에서 " $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 $[0, 1, 0, 0]$ 이 출력되도록 조정할 수 있다"고 하였으므로 적절하다.

6. 정답: ⑤

정답 해설: <그림>의 과정에서 $[h_1, h_2]$ 는 '오늘'과 '정말'을 입력하여 '날씨'를 예측하기 위해 만든 중간 계산 결과이다. 3문단에서 "이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다"고 하였는데, 이는 각 단어에 대해 서로 다른 학습 과정을 거쳐 각각 고유한 2차원 숫자가 부여됨을 의미한다. 따라서 '오늘', '정말', '날씨' 각각에 $[h_1, h_2]$ 와 동일한 값이 부여되는 것은 아니다.

오답 해설:

- ① <그림>에서 '오늘'은 $[1, 0, 0, 0]$, '정말'은 $[0, 0, 1, 0]$ 으로 각각 4개의 성분으로 구성되어 있으므로 적절하다.
- ② <그림>에서 $[h_1, h_2]$ 는 '오늘'의 $[1, 0, 0, 0]$ 과 '정말'의 $[0, 0, 1, 0]$ 각각의 성분을 계산에 반영하여 만들어진 것이므로 적절하다.
- ③ $[h_1, h_2]$ 가 2차원인 것은 임베딩이 원-핫 인코딩의 4차원보다 낮은 차원으로 표현하는 것에 해당하므로 적절하다.
- ④ <그림>에서 '날씨'의 출력값 $[0, 1, 0, 0]$ 에서 두 번째 자리에 1이 위치하는 것은 원-핫 인코딩에서 '날씨'의 색인 값이 두 번째이기 때문이므로 적절하다.

7. 정답: ④

정답 해설: <보기>에서 '먹는다'의 이웃한 단어는 '생선'이고, '마신다'의 이웃한 단어는 '우유'이다. 따라서 두 단어의 이웃한 단어 집합은 서로 다르다. 또한 설명 이웃한 단어가 유사하다고 해도, 학습의 결과로 좌표 평면 위에서 가깝게 나타날 수는 있으나 유클리드 거리가 정확히 0이 되는 것, 즉 두 단어가 완전히 동일한 좌표를 가지게 되는 것은 지문에서 확인할 수 없다.

오답 해설:

- ① '고양이가'는 '고양이가 생선을 먹는다.'에서 '생선'의 이웃이고, '고양이가 우유를 마신다.'에서 '우유'의 이웃이므로, '고양이가'가 제시되면 '생선'과 '우유'가 출력될 확률이 높아지도록 학습된다.
- ② '생선'은 세 문장 중 두 문장에서 등장하며, 이웃 범위 1에서 '고양이가', '먹는다', '강아지가'가 이웃한 단어가 되므로 적절하다.
- ③ '고양이가'와 '강아지가'는 모두 '생선' 앞에서 등장하여 유사한 문맥적 위치를 공유하므로, 좌표 평면 위에서 가깝게 나타날 것이라는 추론은 적절하다.
- ⑤ '생선'과 '우유'는 모두 '고양이가' 다음에 등장하는 이웃 단어로서 유사한 문맥적 위치를 공유하므로, 코사인 유사도가 +1에 가까울 것이라는 추론은 적절하다.

8. 정답: ②

정답 해설: P(3, 4)와 Q(4, 5) 사이의 유클리드 거리는 $\sqrt{\{(4-3)^2 + (5-4)^2\}} = \sqrt{2} \approx 1.41$ 이다. R(8, 1)과 S(9, 2) 사이의 유클리드 거리 역시 $\sqrt{\{(9-8)^2 + (2-1)^2\}} = \sqrt{2} \approx 1.41$ 이다. Q(4, 5)와 R(8, 1) 사이의 유클리드 거리는 $\sqrt{\{(8-4)^2 + (1-5)^2\}} = \sqrt{16+16} = \sqrt{32} \approx 5.66$ 이다. Q와 R 사이의 거리가 R과 S 사이의 거리보다 크다는 것은, '축구'와 '금요일'이 좌표 평면에서 멀리 떨어져 있고 '축구'와 '야구'는 가깝다는 뜻이다. 5문단에서 가까울수록 유사한 의미라 관계가 깊은 것으로 이해할 수 있다고 하였으므로, '축구'는 '금요일'보다 '야구'와 유사한 문장에서 자주 등장했을 것이라는 추론은 적절하다.

오답 해설:

- ① P와 Q 사이의 거리는 $\sqrt{2}$ 이고, P(3, 4)와 T(3, 5) 사이의 거리는 $\sqrt{\{(3-3)^2 + (5-4)^2\}} = 1$ 이다. P와 Q 사이의 거리가 P와 T 사이의 거리보다 크므로, '경계'는

'금용'보다 '주식'과 의미적 유사성이 높다. 선지는 이를 반대로 서술하고 있다.

③ P(3, 4)와 R(8, 1) 사이의 거리는 $\sqrt{\{(8-3)^2 + (1-4)^2\}} = \sqrt{(25+9)} = \sqrt{34} \approx 5.83$ 이다. Q(4, 5)와 S(9, 2) 사이의 거리는 $\sqrt{\{(9-4)^2 + (2-5)^2\}} = \sqrt{(25+9)} = \sqrt{34} \approx 5.83$ 이다. 두 거리가 동일하므로 P와 R 사이의 거리가 Q와 S 사이보다 작다는 전제가 틀렸다.

④ P(3, 4)와 S(9, 2) 사이의 거리는 $\sqrt{\{(9-3)^2 + (2-4)^2\}} = \sqrt{(36+4)} = \sqrt{40} \approx 6.32$ 이다. Q(4, 5)와 R(8, 1) 사이의 거리는 $\sqrt{32} \approx 5.66$ 이다. 두 거리가 동일하지 않으므로 전제가 틀렸다.

⑤ R과 S 사이의 거리와 P와 Q 사이의 거리가 모두 $\sqrt{2}$ 로 동일한 것은 사실이나, 거리가 같다는 것만으로 각 쌍의 단어가 문맥에서 점유하는 의미적 위치가 대칭적이라고 판단할 수는 없다. 두 쌍의 단어가 속한 의미 영역 자체가 다르기 때문이다.

9. 정답: ②

정답 해설: 윗글은 컴퓨터가 사람의 언어를 이해할 수 있도록 단어를 숫자로 표현하는 방법(원-핫 인코딩, 임베딩·워드투벡)을 소개하고, 이렇게 표현된 단어들의 유사성을 측정하는 방식(유클리드 거리, 코사인 유사도)을 설명하고 있다.

오답 해설:

① 컴퓨터가 사람의 언어를 직접 이해하지 못한다는 것은 도입부에서 전제로 제시될 뿐, 그 근본적 원인을 탐구하는 것은 글의 중심 화제가 아니다.

③ 자연어 처리 기술의 역사적 발전 과정이나 시기별 핵심 알고리즘을 시간순으로 서술하는 내용은 윗글에 나타나지 않는다.

④ 유클리드 거리와 코사인 유사도의 수학적 도출 과정은 5문단에서 간략히 정의될 뿐, 글 전체의 중심 화제가 아니다.

⑤ 윗글은 원-핫 인코딩의 한계를 지적하고 이를 보완하는 임베딩을 소개하고 있으므로, 원-핫 인코딩의 우위를 논하는 것은 글의 방향과 반대이다.

10. 정답: ⑤

정답 해설: [A]에서 다루는 원-핫 인코딩은 단어의 색인 값에 따라 1과 0을 부여하는 방법이고, [B]에서 다루는 임베딩(워드투벡)은 원-핫 인코딩으로 부여받은 숫자를 활용하여 전후 문맥을 고려한 학습을 통해 저차원의 숫자를 부여하는 방법이다. 전후 문맥을 고려하는 것은 [B] 이후 3문단에서 설명하는 워드투벡의 학습 과정에 해당하며, [A]에서 다루는 원-핫 인코딩의 특성이 아니다. 선지 ⑤는 양자의 특성을 반대로 서술하고 있다.

오답 해설:

① [A]의 원-핫 인코딩은 1과 0만 사용하고, [B]의 임베딩은 모든 실수를 사용할 수 있으므로 적절하다.

② [A]의 원-핫 인코딩은 단어를 개별적, 독립적으로 표현하여 유사성을 표현하기 어렵고, [B]의 임베딩은 학습 결과 유사한 단어가 가깝게 나타나므로 유사성을 반영할 수 있어 적절하다.

③ [B]에서 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다고 하였으므로, [A]의 결과가 [B]의 입력값으로 쓰인다는 서술은 적절하다.

④ [A]에서 단어 집합의 크기가 4이면 4차원의 숫자를 부여하고, [B]에서는 이를 2차원 등 낮은 차원으로 변환하므로 적절하다.

11. 정답: ②

정답 해설: 3문단에서 ㉠(전후 문맥)을 고려하는 방식은 "앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것"이라 하였다. 4문단에서 ㉡(이웃한 단어)를 출력하는 방식은 "하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법"이라 하였다. 따라서 ②의 서술은 양자의 차이를 정확히 기술하고 있다.

오답 해설:

① ㉠을 고려하는 방식은 앞뒤의 단어, 즉 둘 이상의 단어를 입력해야 하고, ㉡을 출력하는 방식은 하나의 단어만 입력하면 된다. 선지는 양자를 반대로 서술하였다.

③ 이웃한 단어의 범위를 임의로 정할 수 있는 것은 ㉡을 출력하는 방식이다. 선지는 양자를 반대로 서술하였다.

④ 3문단과 4문단 모두에서 학습 과정에 $[h_1, h_2]$ 가 중간 계산 결과로 등장하므로, 양자 모두 $[h_1, h_2]$ 를 거친다.

⑤ 3문단과 4문단 모두에서 원-핫 인코딩 값의 각 성분을 계산하여 $[h_1, h_2]$ 를 만든다고 하였으므로, 양자 모두 원-핫 인코딩 값을 입력으로 사용한다.

12. 정답: ②

정답 해설: ㉠은 "이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다."라는 문장이다. 이는 3~4문단의 학습 과정을 거쳐 임베딩된 단어들이 좌표 평면에서 유사성에 따라 배치됨을 보여 주는 것으로, 1문단에서 지정한 원-핫 인코딩의 한계, 즉 '단어들 간의 유사성이나 관계성을 표현하기 어렵다'는 문제를 임베딩이 실질적으로 극복했음을 뒷받침하는 역할을 한다.

오답 해설:

① ㉠은 두 가지 학습 방법의 결과가 서로 다름을 밝히는 것이 아니라, 학습 결과 전반에 대해 유사한 단어가 가깝게 나타남을 서술하고 있다.

③ ㉠은 원-핫 인코딩의 숫자를 좌표 평면에 표시하는 것에 관한 내용이 아니라, 임베딩으로 표현된 단어들의 좌표 평면 배치를 다루고 있다.

④ ㉠은 $[h_1, h_2]$ 가 최종 좌표로 확정되는 절차를 서술하지 않는다. $[h_1, h_2]$ 는 중간 계산 결과이며, ㉡은 최종적으로 표현된 단어들의 분포 특성을 기술하고 있을 뿐이다.

⑤ ㉠은 단어들이 무작위로 분포함을 전제하지 않는다. 오히려 유사한 문장에서 자주 등장하는 단어들이 가깝게 나타난다는 규칙적 분포를 서술하고 있다.

13. 정답: ④

정답 해설: '남자'(1, 1)와 '여자'(3, 3)의 원점 기준 기울기는 모두 1로 동일하다. <보기>에서 기울기가 동일하면 두 선분이 이루는 각은 0°이고, 코사인 유사도는 +1이라고 하였다. 5문단에서 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타난다고 하였으므로, 코사인 유사도가 +1인 두 단어는 유사한 문장에서 자주 등장했을 것이라는 추론은 적절하다.

오답 해설:

① '왕'의 기울기는 2, '남자'의 기울기는 1로 차이가 1이다. '여왕'의 기울기는 1.5, '여자'의 기울기는 1로 차이가 0.5이다. 기울기 차이가 작을수록 각이 작고 코사인 유사도가 높으므로, '여왕'-'여자' 사이의 코사인 유사도가 '왕'-'남자' 사이보다 높다. 선지는 반대로 서술하였다.

② '여왕'의 기울기는 1.5, '남자'의 기울기는 1로 차이가 0.5이다. '여왕'의 기울기 1.5와 '여자'의 기울기 1의 차이도 0.5이다. 기울기 차이가 동일하므로 두 코사인 유사도는 동일하다. "낮다"는 서술은 적절하지 않다.

③ 코사인 유사도가 +1이라는 것은 두 점이 원점에서 같은 방향에 있다는 뜻이지, 좌표 평면에서 완전히 동일한 위치에 있다는 뜻이 아니다. '남자'(1, 1)와 '여자'(3, 3)는 같은 방향이지만 서로 다른 좌표에 위치해 있다.

⑤ '왕' 기울기 2, '여자' 기울기 1 → 차이 1. '여왕' 기울기 1.5, '남자' 기울기 1 → 차이 0.5. 기울기 차이가 다르므로 두 쌍의 코사인 유사도는 동일하지 않다. "모두 +1"이라는 전제가 틀렸다.

14. 정답: ⑤

정답 해설: $[h_1, h_2]$ 는 2개의 성분으로 이루어져 있으나, 예측 대상 단어의 원-핫 인코딩 값은 단어 집합의 크기와 동일한 차원으로 구성된다. <보기>에서 단어 집합의 크기가 3이므로 원-핫 인코딩 값은 3차원이다. 따라서 $[h_1, h_2]$ 는 예측 대상 단어의 원-핫 인코딩 값과 동일한 차원이 아니다.

오답 해설:

① 방법 X는 앞뒤 단어를 제시하면 그 사이에 들어갈 단어를 출력하는 방법이다. '철수는 사과를 좋아한다.'에서 '사과를'의 앞뒤는 '철수는'과 '좋아한다'이므로, 이들이 입력되면 '사과를'이 출력되도록 학습되는 것은 적절하다.

② 방법 X에서 '철수는'과 '좋아한다'가 입력될 때, 각각의 원-핫 인코딩 값인 $[1, 0, 0]$ 과 $[0, 0, 1]$ 의 각 성분이 계산에 활용되는 것은 3문단의 설명과 일치한다.

③ 방법 Y에서 '사과를'이 입력되고 이웃 범위가 1이면, 이웃한 단어는 '철수는'과 '좋아한다'이므로 이들이 나올 확률이 높아지도록 학습되는 것은 적절하다.

④ 방법 X에서는 주변 단어('철수는', '좋아한다')의 원-핫 인코딩 값을 계산에 반영하여 $[h_1, h_2]$ 를 만들고, 방법 Y에서는 입력 단어('사과를') 자체의 원-핫 인코딩 값을 계산에 반영하여 $[h_1, h_2]$ 를 만드는 것은 3~4문단의 설명과 일치한다.

15. 정답: ③

정답 해설: ㉠은 "유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다."라는 주장이다.

ㄱ: '대통령'과 '국회'는 뉴스 기사에서 유사한 문장(정치 관련 기사)에 자주 함께 등장할 가능성이 높은 단어이다. 이들이 좌표 평면에서 가깝게 나타났다는 것은, 유사한 문장에서 자주 등장하는 단어가 실제로 가깝게 배치된다는 ㉠의 주장을

뒷받침하므로 ㉔를 강화한다.

ㄴ: 특정 전문 분야의 전문 용어들은 해당 분야의 논문에서 유사한 문장에 자주 함께 등장하는 단어들이다. 이들이 좌표 평면에서 하나의 군집을 형성했다는 것은, 유사한 문맥의 단어들이 가깝게 모인다는 ㉔의 주장을 뒷받침하므로 ㉔를 강화한다.

ㄷ: 서로 다른 언어에 속하지만 번역 관계에 있는 단어들이 가깝게 나타났다는 것은, 유사한 의미를 지닌 단어가 가깝게 배치됨을 보여 줄 수 있으나, ㉔의 핵심 조건인 '유사한 문장에서 자주 등장'과는 직접적으로 연결되지 않는다. 서로 다른 언어의 단어들은 동일한 문장에서 자주 함께 등장하기 어렵다. 따라서 ㄷ은 ㉔를 직접적으로 강화하지 않는다.

오답 해설:

- ① ㄱ만 해당하므로 부분적으로 옳으나 ㄴ이 빠져 있어 적절하지 않다.
- ② ㄴ만 해당하므로 부분적으로 옳으나 ㄱ이 빠져 있어 적절하지 않다.
- ④ ㄷ은 ㉔를 강화하지 않으므로 적절하지 않다.
- ⑤ ㄷ은 ㉔를 강화하지 않으므로 적절하지 않다.

16. 정답: ③

정답 해설: 1문단에서 원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이라 하였다. 이 구조적 특성은 차원의 수와 무관하게 유지된다. 차원이 극도로 높아지더라도 각 단어의 숫자에는 여전히 하나의 1과 나머지 0만 존재하므로, 서로 다른 단어의 숫자 간에 유사성이나 관계성이 반영될 여지가 없다. 따라서 단어들 간의 관계성을 표현하기 어려운 한계는 차원이 높아져도 여전히 존재할 것이다.

오답 해설:

- ① 1문단에서 단어 집합의 크기에 따라 각 단어에 부여되는 숫자의 차원이 결정된다고 하였다. 단어 집합의 크기가 커지면 차원도 함께 높아지므로, 차원이 일정하게 유지된다는 서술은 적절하지 않다.
- ② 원-핫 인코딩은 차원이 높아지더라도 단어를 개별적, 독립적으로 표현하는 구조가 변하지 않으므로, 유사성이 자동으로 반영되지 않는다.
- ④ 2문단에서 임베딩은 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현하는 방법이라 하였다. $[h_1, h_2]$ 의 성분 수는 임베딩이 목표로 하는 차원에 의해 결정되는 것이지, 원-핫 인코딩의 차원에 의해 결정되는 것이 아니므로 반드시 함께 높아져야 한다고 단정할 수 없다.
- ⑤ 코사인 유사도는 두 점을 원점과 연결하는 선분이 이루는 각도에 의해 결정되는 것으로, 원-핫 인코딩의 차원과 직접적인 관련이 없다. 차원이 높아지면 코사인 유사도가 항상 0에 가까워진다는 서술은 지문에 근거가 없다.

17. 정답: ④

정답 해설: 4문단은 워드투백의 학습 방법 중 3문단과 다른 또 다른 방법, 즉 하나의 단어가 주어지면 이웃한 단어를 출력하는 방식을 소개하고 있다. 3문단의 학습 방법이 지닌 한계를 지적하거나 이를 극복하기 위한 새로운 알고리즘을 도입하는 내용은 4문단에 나타나지 않는다. 4문단의 방법은 3문단의 방법에 대한 대안이 아니라 워드투백 내의 별도의 학습 방법으로 병렬적으로 제시된 것이다.

오답 해설:

- ① 1문단은 컴퓨터의 언어 이해 한계를 전제로 원-핫 인코딩의 방법을 설명하고, 단어 간 유사성 표현의 어려움이라는 한계를 지적하고 있으므로 적절하다.
- ② 2문단은 원-핫 인코딩의 한계를 보완하는 임베딩을 소개하고, 그 대표적 방법인 워드투백의 기본 원리를 설명하고 있으므로 적절하다.
- ③ 3문단은 전후 문맥을 고려하는 학습 방법을 '오늘'과 '정말' 사이에 '날씨'를 예측하는 사례로 설명하면서, $[h_1, h_2]$ 가 중간 계산 결과임을 밝히고 있으므로 적절하다.
- ⑤ 5문단은 임베딩 결과 유사한 단어가 좌표 평면에서 가깝게 나타남을 설명하고, 유클리드 거리와 코사인 유사도를 소개하고 있으므로 적절하다.

18. 정답: ③

정답 해설:

ㄱ: 원-핫 인코딩에서 각 단어에는 고유한 색인 값에 해당하는 자리에만 1이 부여되고 나머지는 0이 부여된다. 따라서 서로 다른 두 단어의 숫자를 비교하면, 1이 위치하는 자리가 서로 다르므로 두 숫자 모두에서 동시에 1의 값을 가지는 성분의 자리는 존재하지 않는다. 적절하다.

ㄴ: 3문단에서 입력으로 제시되는 앞뒤 단어의 원-핫 인코딩 값은 $[h_1, h_2]$ 를 만들기 위한 계산의 입력으로 사용되는 것이지, 학습의 결과로 원-핫 인코딩 값 자체가 변경되는 것이 아니다.

학습의 결과로 변경되는 것은 계산 과정의 방식이며, 최종 출력은 예측 대상 단어의 원-핫 인코딩 값이다. 적절하지 않다.

ㄷ: 5문단에서 코사인 유사도는 두 선분이 이루는 각이 90° 이면 0, 180° 이면 -1이라 하였다. 둔각은 90° 보다 크고 180° 이하이므로, 코사인 유사도는 0보다 작고 -1 이상인 값을 가진다. 적절하다.

따라서 ㄱ과 ㄷ이 적절하므로 정답은 ③이다.

19. 정답: ①

정답 해설: 1문단에서 ㉔(단어 집합)은 원-핫 인코딩을 수행하기 위해 먼저 만들어야 하는 것으로 제시되어 있다. 또한 2문단에서 워드투백은 원-핫 인코딩으로 부여받은 숫자를 활용하여 학습한다고 하였으므로, 임베딩 역시 단어 집합을 출발점으로 삼는다. 따라서 ㉔은 원-핫 인코딩과 임베딩 모두에서 단어를 숫자로 변환하는 과정의 출발점으로 기능하며, 대상 텍스트에 포함된 단어들의 목록을 확정하는 기초 단위이다.

오답 해설:

- ② 1문단에서 원-핫 인코딩을 수행하기 위해서도 먼저 단어 집합을 만든다고 하였으므로, ㉔이 임베딩에서만 요구되는 전처리 단계라는 서술은 적절하지 않다.
- ③ 1문단에서 원-핫 인코딩은 단어들이 개별적, 독립적으로 표현되어 유사성을 표현하기 어렵다고 하였으므로, 단어 집합이 유사성을 반영하여 구성된다는 서술은 적절하지 않다.
- ④ 단어 집합은 학습 방법의 선택 기준으로 활용되는 것이 아니라, 어떤 학습 방법을 적용하든 그 전제가 되는 단어 목록을 제공하는 역할을 한다.
- ⑤ 단어 집합은 대상 텍스트의 단어 목록이며, 좌표 평면에서 각 단어의 좌표를 직접 결정하는 것은 학습 과정이다.

20. 정답: ②

정답 해설: ㉔는 "이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다."라는 문장이다. 그런데 2문단에서 "실제 임베딩은 수십 수백 차원을 사용한다."라고 하였다. 따라서 ㉔에서 2차원이라고 한 것은 설명의 편의를 위한 단순화된 예시에 해당하며, 실제 워드투백의 결과는 2차원에 국한되지 않는다는 점에서 ㉔의 서술은 실제 적용 범위를 충분히 반영하지 못하고 있다는 비판이 가능하다.

오답 해설:

- ① ㉔는 3문단 말미에 위치하여 전후 문맥을 고려하는 학습 방법의 결과를 서술한 것이다. 그러나 4문단의 다른 학습 방법으로도 동일한 결과에 도달할 수 있다는 점은 ㉔에 대한 비판이 아니라 ㉔의 내용을 보충하는 것에 해당한다. ㉔ 자체가 다른 학습 방법의 존재를 부정하고 있는 것이 아니기 때문이다.
- ③ ㉔는 각 단어에 "고유한" 숫자가 부여된다고 명시적으로 전제하고 있지 않으며, "2차원의 숫자로 표현할 수 있다"고만 서술하고 있으므로, 동일 좌표 가능성의 배제 여부를 비판 지점으로 삼기 어렵다.
- ④ 학습 과정에서 $[h_1, h_2]$ 의 조정 기준에 대한 구체적 메커니즘의 부재는 ㉔에 대한 비판이 아니라 뒷글 전체의 설명 수준에 대한 비판이다. ㉔는 학습의 최종 결과를 요약한 문장일 뿐, 조정 기준을 서술해야 할 위치가 아니다.
- ⑤ 대상 텍스트에 없는 단어에 대한 적용 한계는 ㉔의 내용 자체에 대한 비판이 아니라, 워드투백 방법론 전반의 한계에 관한 것이다. ㉔는 "단어 집합의 모든 단어들에 대해" 수행한다고 하였으므로, 단어 집합에 포함되지 않은 단어의 문제는 ㉔의 서술 범위 밖이다.

21. 정답: ②

정답 해설: ㉔는 "단어를 학습하는 또 다른 과정은 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다."라는 문장이다. 이 방법이 학습의 한 방식으로 성립하려면, 텍스트에서 특정 단어의 앞이나 뒤에 출현하는 단어들에 관한 정보, 즉 단어의 분포적 맥락이 해당 단어의 의미를 파악하는 데 유의미한 단서가 될 수 있다는 것이 전제되어야 한다. 이 전제가 성립하지 않으면 이웃한 단어를 맞추는 학습 자체가 단어의 의미적 표현으로 이어질 수 없다.

오답 해설:

- ① 이웃한 단어들이 동일한 원-핫 인코딩 값을 가져야 한다는 내용은 지문에 나타나지 않으며, 원-핫 인코딩은 각 단어에 고유한 숫자를 부여한다.
- ③ 3문단에서 전후 문맥을 고려하는 방식도 유효한 학습 방법으로 제시되어 있다. ㉔의 방법이 성립하기 위해 3문단의 방법이 불충분해야 할 필요는 없다.
- ④ 4문단에서 이웃한 단어의 범위는 임의로 정할 수 있다고 하였으므로, 텍스트 길이에 비례하여 자동 결정된다는 전제는 적절하지 않다.

㉔ 모든 문장이 동일한 수의 단어로 구성되어야 한다는 조건은 지문에 나타나지 않으며, ㉔의 성립과 무관하다.

22. 정답: ㉔

정답 해설: 5문단에서 코사인 유사도가 0이 되는 것은 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 90°, 즉 직각을 이루는 경우이다. 이는 두 선분의 방향이 서로 직교한다는 의미이지, 두 점이 원점에서 동일한 거리에 위치해 있다는 것을 나타내는 것이 아니다. 원점에서의 거리는 각 점의 좌표값에 의해 결정되는 것으로, 선분 간의 각도와는 독립적인 정보이다.

오답 해설:

㉑ 5문단에서 유클리드 거리와 코사인 유사도 모두 점들 간의 거리를 숫자로 표현하는 방법으로 제시되었으므로, 코사인 유사도가 단어 간 관계를 숫자로 표현하는 방법 중 하나라는 서술은 적절하다.

㉒ 5문단에서 코사인 유사도가 +1이면 각이 0°, 즉 같은 방향이고, 가까울수록 유사한 의미나 관계가 깊다고 하였으므로, +1에 가까울수록 유사한 관계라는 서술은 적절하다.

㉓ 코사인 유사도는 두 선분이 이루는 각으로 측정하는 것이며, 유클리드 거리는 두 점 사이의 직선 거리를 측정하는 것이므로, 코사인 유사도가 직선 거리가 아닌 방향의 유사성을 측정한다는 서술은 적절하다.

㉕ 5문단에서 180°로 반대 방향이면 -1이라 하였으므로, 코사인 유사도가 -1이면 두 점이 원점 기준으로 반대 방향에 있다는 서술은 적절하다.

23. 정답: ㉔

정답 해설: $[h_1, h_2]$ 는 학습 과정에서 만들어지는 중간 계산 결과이며, 예측 대상 단어마다 입력되는 주변 단어가 달라진다. 그러나 중간 계산 결과의 값이 입력 단어만에 의해 결정되는 것인지, 아니면 학습의 반복 과정에서 조정되는 계산 방식에도 영향을 받는 것인지는 지문에서 구체적으로 설명하지 않고 있다. 따라서 입력 단어가 다르다는 사실만으로 두 $[h_1, h_2]$ 가 동일한 값이 될 수 없다고 단정하는 것은 지문의 정보만으로는 확인할 수 없다.

오답 해설:

㉑ 3문단에서 '오늘'과 '정말'이 주어졌을 때 '날씨'를 출력하는 사례가 제시되어 있으며, <보기>에서도 예측 대상 단어의 앞뒤 1개 단어를 입력으로 사용하므로, '날씨' 예측 시 '오늘'과 '정말'이 입력되는 것은 적절하다.

㉒ '정말'의 앞 단어는 '날씨'이고 뒤 단어는 '좋다'이므로, '정말' 예측 시 $[0, 1, 0, 0]$ 과 $[0, 0, 0, 1]$ 이 입력으로 사용되는 것은 적절하다.

㉓ '오늘'은 문장의 맨 앞에 위치하여 앞 단어가 없으므로, <보기>의 가정에 따라 '오늘'을 예측 대상으로 하는 학습은 수행되지 않는다.

㉕ 3문단 말미에서 학습이 완료되면 각 단어를 2차원의 숫자로 표현할 수 있다고 하였으므로, '날씨'와 '정말'이 각각 서로 다른 고유한 2차원 숫자로 표현될 것이라는 추론은 적절하다.

24. 정답: ㉓

정답 해설: '맛있다'(3, 3)와 '최악'(-3, -3) 사이의 유클리드 거리는 $\sqrt{(-3-3)^2 + (-3-3)^2} = \sqrt{36+36} = \sqrt{72}$ 이다. '맛있다'(3, 3)와 '별로'(-2, -2) 사이의 유클리드 거리는 $\sqrt{(-2-3)^2 + (-2-3)^2} = \sqrt{25+25} = \sqrt{50}$ 이다. $\sqrt{72} > \sqrt{50}$ 이므로 '맛있다'와 '최악' 사이의 유클리드 거리가 더 크다. 한편, '맛있다'(3, 3)의 기울기는 1이고 '최악'(-3, -3)의 기울기도 1이며, '별로'(-2, -2)의 기울기도 1이다. 그러나 '맛있다'는 제1사분면(양의 방향), '최악'과 '별로'는 제3사분면(음의 방향)에 위치하므로, 원점에서 각 점까지의 선분이 이루는 각은 180°이다. 따라서 '맛있다'와 '최악' 사이의 코사인 유사도도, '맛있다'와 '별로' 사이의 코사인 유사도도 모두 -1로 동일하다. 따라서 ㉓의 서술은 적절하다.

오답 해설:

㉑ '맛있다'(3, 3)와 '훌륭하다'(4, 4) 사이의 유클리드 거리는 $\sqrt{(4-3)^2 + (4-3)^2} = \sqrt{2} \approx 1.41$ 이다. 유클리드 거리가 0이 아니므로 두 단어가 완전히 동일한 점에 위치한다는 서술은 적절하지 않다.

㉒ '맛있다'(3, 3)는 제1사분면, '별로'(-2, -2)는 제3사분면에 있으므로 원점 기준으로 정반대 방향이다. 코사인 유사도는 -1이지 +1이 아니다. 또한 코사인 유사도가 -1이면 유사한 문장에서 자주 등장한 것이 아니라 반대 방향에 위치한 것이다.

㉕ '보통'(1, 0)은 x축 위(기울기 0), '평범하다'(0, 1)는 y축 위(기울기 없음)에 있으므로 두 선분이 이루는 각은 90°이고 코사인 유사도는 0이다. 코사인 유사도가 0이라는 사실 자체는 정확하나, 선지의 "두 단어가 유사한 문장에서 자주 등장했

더라도"라는 전제는 지문과 양립하기 어렵다. 5문단에서 유사한 문장에서 자주 등장하는 단어들은 가깝게 나타난다고 하였으므로, 코사인 유사도가 0이면 유사한 문장에서 자주 등장했을 것이라는 전제 자체가 좌표 평면의 결과와 모순된다.

㉔ '별로'(-2, -2)와 '최악'(-3, -3) 사이의 유클리드 거리는 $\sqrt{(-3-(-2))^2 + (-3-(-2))^2} = \sqrt{1+1} = \sqrt{2}$ 이다. '맛있다'(3, 3)와 '훌륭하다'(4, 4) 사이의 유클리드 거리도 $\sqrt{2}$ 로 동일하다. 그러나 이 특정 사례에서 거리가 동일하다는 것으로부터 "부정적 의미 단어 쌍의 유클리드 거리는 항상 긍정적 의미 단어 쌍의 유클리드 거리와 같다"고 일반화하는 것은 논리적 비약이다.