

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 1] ㉠ 어휘

1. **색인(索引)**: 어떤 항목을 쉽게 찾을 수 있도록 일정한 순서에 따라 배열한 목록.

동의어: 인덱스(index)

예문: 책 뒤편의 색인을 이용하면 원하는 내용을 빠르게 찾을 수 있다.

2. **부여(賦與)하다**: 사람이나 대상에게 어떤 권한, 자격, 의미 따위를 지니도록 해 주다.

동의어: 수여(授與)하다, 배정(配定)하다

반의어: 박탈(剝奪)하다

예문: 학교는 우수 학생에게 장학금 수혜 자격을 부여했다.

3. **수행(遂行)하다**: 일이나 임무 따위를 계획대로 해내다.

동의어: 실행(實行)하다, 이행(履行)하다

예문: 연구팀은 3년에 걸친 프로젝트를 성공적으로 수행했다.

4. **원소(元素)**: 집합을 구성하는 개별적인 대상 하나하나.

동의어: 요소(要素), 성분(成分)

예문: 집합 {1, 2, 3}에서 각각의 숫자는 하나의 원소이다.

5. **직관적(直觀的)**: 판단이나 추리 따위의 사유 과정을 거치지 않고 대상을 곧바로 파악하는.

반의어: 분석적(分析的)

예문: 이 프로그램은 직관적인 인터페이스를 갖추어 초보자도 쉽게 사용할 수 있다.

6. **유사성(類似性)**: 둘 이상의 대상이 서로 비슷한 성질이나 특성.

동의어: 유사도(類似度), 근사성(近似性)

반의어: 이질성(異質性)

예문: 두 언어 사이의 유사성을 분석하면 역사적 연관 관계를 추정할 수 있다.

7. **관계성(關係性)**: 둘 이상의 사물이나 현상이 서로 맺고 있는 연관의 정도나 성질.

동의어: 연관성(聯關性), 상관성(相關性)

예문: 수면 시간과 학업 성취도 사이의 관계성을 조사한 논문이 발표되었다.

8. **차원(次元)**: 공간이나 수학적 대상의 크기나 범위를 나타내는 독립적인 변수의 수.

예문: 3차원 공간에서는 가로, 세로, 높이의 세 방향으로 위치를 표현한다.

9. **실수(實數)**: 유리수와 무리수를 통틀어 이르는 수.

예문: 수직선 위의 모든 점은 하나의 실수에 대응된다.

10. **성분(成分)**: 하나의 대상을 이루고 있는 개별 요소.

동의어: 요소(要素), 구성분(構成分)

예문: 벡터의 각 성분을 더하면 새로운 벡터를 얻을 수 있다.

11. **전후 문맥(前後文脈)**: 어떤 단어나 문장의 앞뒤에 오는 말의 흐름이나 연결 관계.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

동의어: 맥락(脈絡), 문맥(文脈)

예문: 전후 문맥을 살피면 낯선 단어의 뜻을 짐작할 수 있다.

12. 예측(豫測)하다: 앞으로 일어날 일을 미리 짐작하여 헤아리다.

동의어: 전망(展望)하다, 추정(推定)하다

예문: 기상청은 이번 주말에 비가 올 것으로 예측했다.

13. 조정(調整)하다: 어떤 기준이나 목적에 맞도록 바로잡거나 알맞게 맞추다.

동의어: 조절(調節)하다

예문: 화면의 밝기를 눈이 편안한 수준으로 조정했다.

14. 임의(任意): 일정한 기준이나 규칙 없이 마음대로.

동의어: 무작위(無作為)로, 자의(恣意)적으로

예문: 실험 참가자를 임의로 두 집단으로 나누어 결과를 비교했다.

15. 유클리드 거리: 두 점 사이를 잇는 직선의 길이로, 피타고라스의 정리를 이용하여 구한 거리.

예문: 좌표 평면에서 (1, 2)와 (4, 6) 사이의 유클리드 거리는 5이다.


16. 코사인 유사도: 두 벡터가 이루는 각도를 기반으로 방향의 유사한 정도를 나타내는 값.

예문: 두 문서의 코사인 유사도가 1에 가까울수록 내용이 비슷하다고 판단한다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 2] 문장 독해 — 학생용 (빈칸 버전)

1) 컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다. 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 ㉠원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다. 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다. 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.	1) 중심어(구) _____, _____ 문장 독해 • 1 컴퓨터는 사람의 언어를 직접 이해할 수 없음. → 컴퓨터가 사람의 언어를 이해할 수 있도록 _____해 주어야 함. • 2 _____의 개념 : 표현하고 싶은 단어의 _____ 값에 1을 _____하고 나머지는 0을 부여하는 방법. -3 원-핫 인코딩 수행 절차 -(부연) : 먼저 대상이 되는 텍스트의 _____을 만들. -4 -(예시) : '오늘 날씨 정말 좋다.' → 단어 집합 {오늘, 날씨, 정말, 좋다}, 크기 = _____, 각 단어에 _____의 고유한 숫자를 부여. • 5 원-핫 인코딩의 한계 : _____이고 _____하지만, 단어들이 _____, _____으로 표현되기 때문에 단어들 간의 _____이나 _____을 표현하기 어려움. 중심 내용 _____
2) 이러한 단점을 개선하려는 시도가 ㉡임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다. 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다. 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.	2) 중심어(구) _____, _____, _____ 문장 독해 • 1 _____의 개념 : 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 _____ 차원으로 표현할 수 있는 방법. → 1과 0뿐만 아니라 모든 _____를 사용할 수 있음. 실제 임베딩은 _____ 차원을 사용. • 2 임베딩의 방법 중 대표적인 것 : _____(Word2Vec). -3 워드투벡은 _____으로 부여받은 숫자를 활용. -(부연) -4 -(예시) : 원-핫 인코딩으로 부여된 단어 집합 → 적절히 계산하여 _____의 고유한 숫자를 부여. • 3 이 과정을 _____이라고 함. 중심 내용 _____
3) 워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다. '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 $\odot [h_1, h_2]$를 만든다. 이때 $[h_1, h_2]$는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다. 그리고 $[h_1, h_2]$의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.	3) 중심어(구) _____, _____ 문장 독해 • 1 워드투벡에서 단어를 학습하는 방법 ① : _____을 고려하여 단어를 맞추는 것. -2 -(부연) : 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 _____하도록 학습. • 3 '날씨' 출력 과정 -(예시) : '오늘' [1, 0, 0, 0]과 '정말' [0, 0, 1, 0]의 각 _____을 적절히 계산 → _____를 만들. • 4 $[h_1, h_2]$의 의미 : '날씨'를 _____하기 위해 _____들을 참고하여 만든 _____결과. • 5 $[h_1, h_2]$의 각 성분을 또 다른 방식으로 계산 → '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 _____할 수 있음. • 6 이러한 과정을 단어 집합의 _____들에 대해 수행 → 각각의 단어를 _____의 숫자로 표현 가능. 중심 내용 _____



<그림>

4)

단어를 학습하는 또 다른 과정은 [A]하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다. 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다. 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 @나올 확률이 높아지도록 학습한다.

4)

중심어(구) _____, _____

문장 독해

- 1 워드투벡에서 단어를 학습하는 방법 ② : 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법. → 어떤 단어가 제시되면 _____를 출력하도록 학습.
- 2 이웃한 단어의 범위 : _____로 정할 수 있음.
-3 -(예시) : '날씨'에 이웃한 단어의 범위를 1로 정하면 '오늘'과 '정말', 2로 정하면 '오늘', '정말', '좋다'.
- 4 학습 과정 -(예시) : '날씨' [0, 1, 0, 0] 제시 → 각 성분을 적절히 계산 → $[h_1, h_2]$ → 또 다른 방식으로 계산 → '오늘'과 '정말'이 _____도록 학습.

중심 내용 _____

5)

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다. 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다. 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다. 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 로 직각을 이루면 0, 180° 로 반대 방향이면 -1의 값으로 나타낸다.

5)

중심어(구) _____, _____

문장 독해

- 1 임베딩으로 표현된 단어들은 2차원의 _____ 위의 점으로 그려질 수 있음.
- 2 _____에서 자주 등장하는 단어들은 좌표 평면 위에서 _____ 나타남. → 점들이 가까울수록 _____이나 관계가 깊은 것.
- 3 _____ : 피타고라스의 정리를 이용해 두 점 사이를 잇는 _____의 길이를 구한 값.
- 4 _____ : 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 _____, 90° 이면 _____, 180° 이면 _____의 값.


중심 내용 _____

글의 주제 : _____

[Part 3] ㉠ 독해 포인트(설명서) — 학생용 (빈칸 버전)

컴퓨터는 사람의 언어를 직접 이해할 수 없기 때문에, 컴퓨터가 이를 이해할 수 있도록 표현하는 방법이 필요하다. 그중 _____은 표현하고 싶은 단어의 색인 값에 1을, 나머지는 0을 부여하는 방법으로, _____이고 단순하지만 단어들이 개별적, 독립적으로 표현되어 단어들 간의 _____이나 _____을 표현하기 어렵다는 한계가 있다. 이를 개선하기 위해 _____이 등장하였는데, 임베딩은 원-핫 인코딩에 비해 상대적으로 _____차원으로 단어를 표현하며, 모든 _____를 사용할 수 있다. 임베딩의 대표적인 방법인 _____은 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 _____의 고유한 숫자를 부여하는 _____을 수행한다. 워드투벡의 학습 방법에는 _____을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 _____를 맞추는 방법이 있다. 이렇게 표현된 단어들은 _____위의 점으로 그려지며, 유사한 문장에서 자주 등장하는 단어들은 _____나타난다. 단어 간 거리는 _____와 _____로 측정할 수 있다.

워드투벡 임베딩 결과



<그래프 해설>

위 그래프는 워드투벡을 사용하여 음식 평가 단어들을 _____의 좌표 평면 위에 _____한 결과이다. 각 단어는 (x, y) 좌표로 표현되며, '훌륭하다'(4, 4), '맛있다'(3, 3), '보통'(1, 0), '평범하다'(0, 1), '별로'(-2, -2), '최악'(-3, -3) 등이 배치되어 있다.

㉠ 유클리드 거리 해석

그래프에서 두 점 사이의 _____(두 점 사이의 직선)이 짧을수록 두 단어의 의미가 _____. 예를 들어, '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 직선 거리가 _____의미적으로 유사한 반면, '맛있다'(3, 3)와 '최악'(-3, -3)은 직선 거리가 _____의미적으로 _____임을 알 수 있다.

㉡ 코사인 유사도 해석

그래프에서 원점(0, 0)에서 각 점까지의 _____이 이루는 각도로 유사도를 판단한다. '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 원점에서 같은 방향(y = x 직선 위)에 있으므로 두 선분이 이루는 각이 _____에 가까워 코사인 유사도가 _____에 가깝다. '보통'(1, 0)은 x축 위에 있어 원점에서의 선분이 '맛있다'(3, 3)까지의 선분과 _____를 이루므로 코사인 유사도는 약 _____으로, +1과 0의 _____에 해당한다. '평범하다'(0, 1)는 y축 위에 있어 '보통'(1, 0)과의 선분이 이루는 각이 _____이므로 코사인 유사도는 _____이다. 또한, '최악'(-3, -3)은 원점에서 '훌륭하다'(4, 4)와 _____에 위치하므로 두 선분이 이루는 각이 _____이고, 코사인 유사도는 _____이다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 4] ◎ 핵심 개념 — 학생용 (빈칸 버전)

포인트 1. _____

_____은 표현하고 싶은 단어의 _____ 값에 1을 부여하고 나머지에는 0을 부여하는 방법이다. 대상이 되는 텍스트로부터 _____을 만들고, 단어 집합의 크기에 따라 각 단어에 고유한 숫자를 부여한다. 이 방법은 _____이고 단순하지만, 단어들이 _____, _____으로 표현되어 단어들 간의 _____이나 _____을 표현할 수 없다는 한계가 있다.

포인트 2. _____

_____은 원-핫 인코딩에 비해 상대적으로 _____차원으로 단어를 표현할 수 있는 방법이다. 1과 0뿐만 아니라 모든 _____를 사용할 수 있으며, 실제로는 _____차원을 사용한다. 원-핫 인코딩의 단점인 단어들 간의 유사성·관계성 표현 문제를 개선하기 위해 제시되었다.

포인트 3. _____

_____ (Word2Vec)은 _____의 대표적인 방법으로, _____으로 부여받은 숫자를 활용하여 단어에 저차원의 고유한 숫자를 부여한다. 학습 방법에는 _____을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 _____를 맞추는 방법이 있다. 학습 과정에서 입력 단어의 각 성분을 계산하여 _____인 $[h_1, h_2]$ 를 만들고, 이를 다시 계산하여 목표 단어가 출력되도록 _____한다.

포인트 4. _____와 _____

임베딩으로 표현된 단어들은 _____위의 점으로 나타나며, 유사한 문장에서 자주 등장하는 단어들은 _____나타난다. _____는 피타고라스의 정리를 이용해 두 점 사이의 _____길이를 구한 값이고, _____는 두 선분이 이루는 각이 0° 이면 _____, 90° 이면 _____, 180° 이면 _____로 나타낸다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 5] ㉠ 내용 구조 — 학생용 (빈칸 버전)

포인트 1. 원-핫 인코딩과 임베딩의 비교

구분	원-핫 인코딩	임베딩
표현 방식	_____	_____
사용 값	_____	_____
차원	_____	_____
단어 간 관계	_____	_____
장점	_____	_____
단점	_____	-

포인트 2. 워드투벡의 두 가지 학습 방법

구분	방법 ①	방법 ②
핵심 원리	_____	_____
입력	_____	_____
출력	_____	_____
이웃 단어 범위	-	_____


포인트 3. 유사도 측정 방법

구분	유클리드 거리	코사인 유사도
원리	_____	_____
값의 범위/의미	_____	_____

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 6] 문장 독해 — 정답 버전 (괄호 해설 포함)

1) 컴퓨터는 사람의 언어를 직접 이해할 수 없다. 따라서 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 한다.(컴퓨터 언어 표현의 필요성) 컴퓨터가 사람의 언어를 이해할 수 있도록 표현하는 방법에는 여러 가지가 있을 수 있는데, 그중 ㉠원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법이다.(원-핫 인코딩의 개념) 원-핫 인코딩을 수행하기 위해서는 먼저 대상이 되는 텍스트의 단어 집합을 만든다. 예를 들어 '오늘 날씨 정말 좋다.'라는 한 문장으로 이루어진 텍스트를 대상으로 한다고 가정하면, 단어 집합은 {오늘, 날씨, 정말, 좋다}가 되고 집합의 원소가 되는 단어의 개수가 4개이므로 단어 집합의 크기는 4가 된다. 단어 집합의 크기에 따라 각각의 단어에 [1, 0, 0, 0], [0, 1, 0, 0], [0, 0, 1, 0], [0, 0, 0, 1]과 같이 4차원의 고유한 숫자를 부여하는 것이 원-핫 인코딩이다.(원-핫 인코딩 수행 절차 - 예시) 원-핫 인코딩은 직관적이고 단순하지만 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어렵다.(원-핫 인코딩의 한계)	1) 중심어(구) 원-핫 인코딩, 단어 집합 문장 독해 • 1 컴퓨터는 사람의 언어를 직접 이해할 수 없음. → 컴퓨터가 사람의 언어를 이해할 수 있도록 표현해 주어야 함. • 2 원-핫 인코딩의 개념 : 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지는 0을 부여하는 방법. - 3 원-핫 인코딩 수행 절차 -(부연) : 먼저 대상이 되는 텍스트의 단어 집합을 만들. - 4 -(예시) : '오늘 날씨 정말 좋다.' → 단어 집합 {오늘, 날씨, 정말, 좋다}, 크기 = 4, 각 단어에 4차원의 고유한 숫자를 부여. • 5 원-핫 인코딩의 한계 : 직관적이고 단순하지만, 단어들이 개별적, 독립적으로 표현되기 때문에 단어들 간의 유사성이나 관계성을 표현하기 어려움. 중심 내용 원-핫 인코딩의 개념, 수행 절차, 한계
2) 이러한 단점을 개선하려는 시도가 ㉡임베딩을 통해 이루어질 수 있다. 임베딩은 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법으로, 1과 0뿐만 아니라 모든 실수를 사용할 수 있다.(임베딩의 개념) 실제 임베딩은 수십 수백 차원을 사용한다. 임베딩의 방법 중 대표적인 것이 워드투벡(Word2Vec)이다. 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용한다.(워드투벡의 특징) 예를 들어 [1, 0, 0, 0], [0, 1, 0, 0], ...과 같이 원-핫 인코딩으로 고유한 숫자들이 부여된 단어 집합이 있다면 이들을 적절히 계산하여 [0.1, 0.2], [5, 2], ...와 같은 2차원의 고유한 숫자를 부여하는 것이다. 이 과정을 학습이라고 한다.(워드투벡의 학습 과정 - 예시)	2) 중심어(구) 임베딩, 워드투벡, 학습 문장 독해 • 1 임베딩의 개념 : 단어를 (x, y)의 2차원 좌표와 같이 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 표현할 수 있는 방법. → 1과 0뿐만 아니라 모든 실수를 사용할 수 있음. 실제 임베딩은 수십 수백 차원을 사용. • 2 임베딩의 방법 중 대표적인 것 : 워드투벡(Word2Vec). - 3 워드투벡은 원-핫 인코딩으로 부여받은 숫자를 활용. - (부연) - 4 -(예시) : 원-핫 인코딩으로 부여된 단어 집합 → 적절히 계산하여 2차원의 고유한 숫자를 부여. • 3 이 과정을 학습이라고 함. 중심 내용 임베딩의 개념과 워드투벡의 학습 과정
3) 워드투벡에서 단어를 학습하는 방법 중 하나는 전후 문맥을 고려하여 단어를 맞추는 것이다. 예를 들어 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습하는 것이다.(워드투벡 학습 방법 ① : 전후 문맥 고려) '오늘'과 '정말'이 주어졌을 때 그 사이에 들어갈 '날씨'를 출력하는 경우를 살펴보자. <그림>과 같이 '오늘'에 해당하는 [1, 0, 0, 0]과 '정말'에 해당하는 [0, 0, 1, 0]의 각 성분을 적절히 계산하여 ㉢[h₁, h₂]를 만든다. 이때 [h₁, h₂]는 '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과이다.([h₁, h₂]의 의미 = 중간 계산 결과) 그리고 [h₁, h₂]의 각 성분을 또 다른 방식으로 계산하여 '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있다. 이러한 과정을 단어 집합의 모든 단어들에 대해 수행하면 각각의 단어를 2차원의 숫자로 표현할 수 있다.(학습 결과 : 단어를 2차원 숫자로 표현)	3) 중심어(구) 전후 문맥, 중간 계산 결과 문장 독해 • 1 워드투벡에서 단어를 학습하는 방법 ① : 전후 문맥을 고려하여 단어를 맞추는 것. - 2 -(부연) : 앞뒤의 단어를 제시하면 그 사이에 들어갈 적절한 하나의 단어를 출력하도록 학습. • 3 '날씨' 출력 과정 -(예시) : '오늘' [1, 0, 0, 0]과 '정말' [0, 0, 1, 0]의 각 성분을 적절히 계산 → [h₁, h₂]를 만들. - 4 [h₁, h₂]의 의미 : '날씨'를 예측하기 위해 주변 단어들을 참고하여 만든 중간 계산 결과. • 5 [h₁, h₂]의 각 성분을 또 다른 방식으로 계산 → '날씨'에 해당하는 [0, 1, 0, 0]이 출력되도록 조정할 수 있음. • 6 이러한 과정을 단어 집합의 모든 단어들에 대해 수행 → 각각의 단어를 2차원의 숫자로 표현 가능. 중심 내용 전후 문맥을 고려한 워드투벡의 학습 방법과 [h₁, h₂]



<그림>

의 역할

4)

단어를 학습하는 또 다른 과정은 [A]하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법이다. 즉 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습하는 것이다.(워드투벡 학습 방법 ② : 이웃한 단어 맞추기) 이때 앞이나 뒤에 이어질 단어의 범위는 임의로 정할 수 있는데, 만약 '날씨'에 이웃한 단어의 범위를 1로 정한다면 '오늘'과 '정말'이 되고, 2로 정한다면 '오늘', '정말', '좋다'가 된다.(이웃한 단어의 범위 설정 -예시) 예를 들어 '날씨'에 이웃한 단어의 범위를 1로 정하고, '날씨'에 해당하는 [0, 1, 0, 0]이 제시되면 [0, 1, 0, 0]의 각 성분을 적절히 계산하여 $[h_1, h_2]$ 를 만들고, $[h_1, h_2]$ 의 각 성분을 또 다른 방식으로 계산하여 '오늘'과 '정말'이 @나올 확률이 높아지도록 학습한다.(학습 과정 -예시)

5)

이렇게 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있는데, 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타날 것이다.(임베딩 결과의 시각화) 즉 각각의 단어에 해당하는 점들이 가까우면 가까울수록 유사한 의미나 관계가 깊은 것으로 이해할 수 있다.(=점 간 거리가 가까울수록 의미적 유사성이 높음) 점들 간의 거리 역시 숫자로 표현될 수 있는데, 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값이다.(유클리드 거리의 개념) 코사인 유사도는 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 로 직각을 이루면 0, 180° 로 반대 방향이면 -1의 값으로 나타낸다.(코사인 유사도의 개념)

4)

중심어(구) 이웃한 단어, 나올 확률

문장 독해

- 1 워드투벡에서 단어를 학습하는 방법 ② : 하나의 단어가 주어지면 앞이나 뒤에 이어질 단어를 맞추는 방법. → 어떤 단어가 제시되면 이웃한 단어를 출력하도록 학습.
- 2 이웃한 단어의 범위 : 임의로 정할 수 있음.
-3 -(예시) : '날씨'에 이웃한 단어의 범위를 1로 정하면 '오늘'과 '정말', 2로 정하면 '오늘', '정말', '좋다'.
- 4 학습 과정 -(예시) : '날씨' [0, 1, 0, 0] 제시 → 각 성분을 적절히 계산 → $[h_1, h_2]$ → 또 다른 방식으로 계산 → '오늘'과 '정말'이 나올 확률이 높아지도록 학습.

중심 내용 이웃한 단어를 맞추는 워드투벡의 또 다른 학습 방법

5)

중심어(구) 유클리드 거리, 코사인 유사도

문장 독해

- 1 임베딩으로 표현된 단어들은 2차원의 좌표 평면 위의 점으로 그려질 수 있음.
- 2 유사한 문장에서 자주 등장하는 단어들은 좌표 평면 위에서 가깝게 나타남. → 점들이 가까울수록 유사한 의미이나 관계가 깊은 것.
- 3 유클리드 거리 : 피타고라스의 정리를 이용해 두 점 사이를 잇는 직선의 길이를 구한 값.
- 4 코사인 유사도 : 두 점을 각각 원점과 연결하는 두 선분이 이루는 각이 0° 이면 +1, 90° 이면 0, 180° 이면 -1의 값.


중심 내용 임베딩 결과의 시각화와 유사도 측정 방법

글의 주제 : 컴퓨터가 사람의 언어를 이해하기 위한 표현 방법 (원-핫 인코딩, 임베딩)과 단어 간 유사도 측정 방법

[Part 7] ◎ 독해 포인트(설명서) — 정답 버전

컴퓨터는 사람의 언어를 직접 이해할 수 없기 때문에, 컴퓨터가 이를 이해할 수 있도록 표현하는 방법이 필요하다. 그중 **원-핫 인코딩**은 표현하고 싶은 단어의 색인 값에 1을, 나머지는 0을 부여하는 방법으로, **직관적**이고 단순하지만 단어들이 개별적, 독립적으로 표현되어 단어들 간의 **유사성**이나 **관계성**을 표현하기 어렵다는 한계가 있다. 이를 개선하기 위해 **임베딩**이 등장하였는데, 임베딩은 원-핫 인코딩에 비해 상대적으로 **낮은** 차원으로 단어를 표현하며, 모든 **실수**를 사용할 수 있다. 임베딩의 대표적인 방법인 **워드투벡**은 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 **2차원**의 고유한 숫자를 부여하는 **학습**을 수행한다. 워드투벡의 학습 방법에는 **전후 문맥**을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 **이웃한 단어**를 맞추는 방법이 있다. 이렇게 표현된 단어들은 **좌표 평면** 위의 점으로 그려지며, 유사한 문장에서 자주 등장하는 단어들은 **가깝게** 나타난다. 단어 간 거리는 **유클리드 거리**와 **코사인 유사도**로 측정할 수 있다.

워드투벡 임베딩 결과



<그래프 해설>

위 그래프는 워드투벡을 사용하여 음식 평가 단어들을 **2차원**의 좌표 평면 위에 **임베딩**한 결과이다. 각 단어는 (x, y) 좌표로 표현되며, '훌륭하다'(4, 4), '맛있다'(3, 3), '보통'(1, 0), '평범하다'(0, 1), '별로'(-2, -2), '최악'(-3, -3) 등이 배치되어 있다.

① 유클리드 거리 해석

그래프에서 두 점 사이의 **직선**(두 점 사이의 직선)이 짧을수록 두 단어의 의미가 **유사하다**. 예를 들어, '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 직선 거리가 **짧아** 의미적으로 유사한 반면, '맛있다'(3, 3)와 '최악'(-3, -3)은 직선 거리가 **멀어** 의미적으로 **상이함**을 알 수 있다.

② 코사인 유사도 해석

그래프에서 원점(0, 0)에서 각 점까지의 **선분**이 이루는 각도로 유사도를 판단한다. '맛있다'(3, 3)와 '훌륭하다'(4, 4)는 원점에서 같은 방향($y = x$ 직선 위)에 있으므로 두 선분이 이루는 각이 **0°**에 가까워 코사인 유사도가 **+1**에 가깝다. '보통'(1, 0)은 x축 위에 있어 원점에서의 선분이 '맛있다'(3, 3)까지의 선분과 **45°**를 이루므로 코사인 유사도는 약 **0.707**으로, +1과 0의 **중간**에 해당한다. '평범하다'(0, 1)는 y축 위에 있어 '보통'(1, 0)과의 선분이 이루는 각이 **90°**이므로 코사인 유사도는 **0**이다. 또한, '최악'(-3, -3)은 원점에서 '훌륭하다'(4, 4)와 **정반대 방향**에 위치하므로 두 선분이 이루는 각이 **180°**이고, 코사인 유사도는 **-1**이다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 8] ◎ 핵심 개념 — 정답 버전

포인트 1. 원-핫 인코딩

원-핫 인코딩은 표현하고 싶은 단어의 색인 값에 1을 부여하고 나머지에는 0을 부여하는 방법이다. 대상이 되는 텍스트로부터 단어 집합을 만들고, 단어 집합의 크기에 따라 각 단어에 고유한 숫자를 부여한다. 이 방법은 직관적이고 단순하지만, 단어들이 개별적, 독립적으로 표현되어 단어들 간의 유사성이나 관계성을 표현할 수 없다는 한계가 있다.

포인트 2. 임베딩

임베딩은 원-핫 인코딩에 비해 상대적으로 낮은 차원으로 단어를 표현할 수 있는 방법이다. 1과 0뿐만 아니라 모든 실수를 사용할 수 있으며, 실제로는 수십 수백 차원을 사용한다. 원-핫 인코딩의 단점인 단어들 간의 유사성·관계성 표현 문제를 개선하기 위해 제시되었다.

포인트 3. 워드투벡

워드투벡(Word2Vec)은 임베딩의 대표적인 방법으로, 원-핫 인코딩으로 부여받은 숫자를 활용하여 단어에 저차원의 고유한 숫자를 부여한다. 학습 방법에는 전후 문맥을 고려하여 앞뒤 단어 사이의 단어를 맞추는 방법과, 하나의 단어가 주어지면 이웃한 단어를 맞추는 방법이 있다. 학습 과정에서 입력 단어의 각 성분을 계산하여 중간 계산 결과인 $[h_1, h_2]$ 를 만들고, 이를 다시 계산하여 목표 단어가 출력되도록 조정한다.

포인트 4. 유클리드 거리와 코사인 유사도

임베딩으로 표현된 단어들은 좌표 평면 위의 점으로 나타나며, 유사한 문장에서 자주 등장하는 단어들은 가깝게 나타난다. 유클리드 거리는 피타고라스의 정리를 이용해 두 점 사이의 직선 길이를 구한 값이고, 코사인 유사도는 두 선분이 이루는 각이 0° 이면 +1, 90° 이면 0, 180° 이면 -1로 나타낸다.

2027 수능특강 독서 (2부 적용학습 과학기술 07강) '임베딩과 유사도 표현'

[Part 9] ㉠ 내용 구조 — 정답 버전

포인트 1. 원-핫 인코딩과 임베딩의 비교

구분	원-핫 인코딩	임베딩
표현 방식	색인 값에 <u>1</u> 을 부여, 나머지 <u>0</u>	상대적으로 <u>낮은 차원</u> 의 실수 벡터
사용 값	<u>1</u> 과 <u>0</u> 만 사용	모든 <u>실수</u> 사용 가능
차원	<u>단어 집합의 크기</u> 와 동일	상대적으로 <u>낮은 차원</u> (수십~수백)
단어 간 관계	<u>표현 불가</u> (개별적, 독립적)	<u>표현 가능</u> (유사 단어 근접 배치)
장점	<u>직관적</u> 이고 <u>단순</u>	단어 간 <u>유사성·관계성</u> 표현 가능
단점	단어 간 <u>유사성·관계성</u> 표현 어려움	-

포인트 2. 워드투벡의 두 가지 학습 방법

구분	방법 ①	방법 ②
핵심 원리	<u>전후 문맥</u> 을 고려하여 중간 단어 맞추기	하나의 단어로 <u>이웃한 단어</u> 맞추기
입력	<u>앞뒤 단어</u> (2개)	<u>하나</u> 의 단어
출력	사이에 들어갈 <u>하나</u> 의 단어	<u>이웃한 단어</u> 들
이웃 단어 범위	-	<u>임의</u> 로 설정 가능

포인트 3. 유사도 측정 방법

구분	유클리드 거리	코사인 유사도
원리	<u>피타고라스의 정리</u> 를 이용해 두 점 사이 <u>직선</u> 길이 계산	두 선분이 이루는 <u>각도</u> 기반
값의 범위/의미	값이 <u>작을수록</u> 유사	$0^\circ \rightarrow +1$, $90^\circ \rightarrow 0$, $180^\circ \rightarrow -1$